Metagenomsequenzierung und bioinformatische Datenanalyse

Bachelorarbeit

zur Erlangung des akademischen Grades

„Bachelor of Science in Engineering“

Studiengang:

Bio- und Lebensmitteltechnologie

Management Center Innsbruck

Betreuende/r:

M.Sc. Thomas Klammsteiner

Gutachter/-in:

FH-Prof. Dr. Christoph Griesbeck

Verfasser/in:

Scharinger Lisa

1610351034

Eidesstattliche Erklärung

Ich erkläre hiermit an Eides statt, dass ich die vorliegende Bachelorarbeit selbstständig angefertigt habe. Die aus fremden Quellen direkt oder indirekt übernommenen Gedanken sind als solche kenntlich gemacht.

Die Arbeit wurde bisher weder in gleicher noch in ähnlicher Form einer anderen Prüfungsbehörde vorgelegt und auch noch nicht veröffentlicht.

Innsbruck, am _____ _____

Danksagung

An dieser Stelle möchte ich allen danken, die mich während des Studiums und des Schreibens der Bachelorarbeit unterstützt haben.

Herzlich bedanken möchte ich mich beginnend bei meinem Betreuer Thomas Klammsteiner, M.Sc. (Universität Innsbruck, Institut für Mikrobiologie), der mir Grundsteine hilfreicher Literatur, sowie Vorbereitung zum Aufbau meiner Arbeit gegeben und meine Arbeit gegengelesen hat. Große Hilfe war Thomas besonders bei Erklärung des Ablaufes einer bioinformatischen Analyse, die die Grundlage für das Anwendungsbeispiel gelegt hat.

Weiterer großer Dank gilt meinem Gutachter Herrn FH-Prof. Dr. Christoph Griesbeck, der mich von Anfang an mit der Themenfindung der Bachelorarbeit, über Fragen und Hinweise bis hin zur Gegenlesung der Arbeit unterstützt hat.

Abschließend möchte ich noch meiner Familie und meinen wichtigsten Freunden danken, die mich von Beginn an meines Studiums immer unterstützten, sich dazu bereit erklärten meine Abschlussarbeit zu lesen und keine Scheu vor Verbesserungen und hilfreiche Inputs hatten.

Kurzfassung

Der ständige Fortschritt von Sequencing-Methoden im letzten Jahrzehnt führt dazu, dass Analysen von mikrobiellen Gemeinschaften nicht mehr nur für Konzerne und als große Projekte möglich sind, sondern ebenso für kleine Labore, Universitäten und Hochschulen. Betrachtet man speziell Metagenomprojekte, steht die Analyse der 16S rRNA im Fokus. In dieser Arbeit wird neben den drei Generationen an Sequencing-Methoden der grundlegende Workflow zur bioinformatischen Untersuchung von Mikrobiomen beschrieben. Der Workflow umfasst von der Probensammlung bis zur statistischen Analyse die wichtigsten Prozesse und teilt sich in zwei große Kapitel – die Schritte vor, sowie die Schritte nach der Sequenzierung. Der Workflow Post-Sequencing stellt das umfangreichste Kapitel dar, denn während der bioinformatischen Datenaufarbeitung und -analyse können Fehler übersehen werden oder zusätzlich hinzukommen. Diese Fehler würden zu einer falschen Darstellung der untersuchten Probe führen und z.B. die Artzusammensetzung der mikrobiellen Gemeinschaft als Gesamtbild nicht korrekt repräsentieren. Wichtig ist, den Workflow an die aktuelle Forschungsfrage der Projekte anzupassen. Im Anschluss an die theoretische Aufarbeitung von Sequenzierungsprozessen findet sich ein Anwendungsbeispiel, das auf Basis der bioinformatischen Analysesoftware „mothur“ die Verarbeitung von Sequenzdatensätzen darstellt. Die beschriebenen Schritte der Arbeit dienen als Übersicht und Grundlage der möglichen Prozesse einer bioinformatischen Datenanalyse, müssen aber zu aktuellen Projekten stets adaptiert werden, um die bestmögliche Analyse zu erlauben.

Abstract

Developments of sequencing methods in the last decade make biological community analysis possible not only for corporations and large projects but also for small laboratories and universities. In terms of metagenomic projects, the analysis of 16S rRNA is the basis for the study. Besides the three generations of sequencing methods this work describes the basic workflow for the bioinformatic analysis of biological communities. The workflow from sample collection to statistical analysis covers the most crucial process steps. It is divided into two major chapters – the steps before and after sequencing. The most important chapter is the post-sequencing workflow. During the bioinformatic data processing and analysis in the workflow, different errors can be added or overlooked. These errors would lead to misinterpretation and incorrect representation of the analysed community. Thus, it is important to adapt each workflow to the current research task of ongoing projects. Finally, an example of application is described using the bioinformatic analysis tool “mothur” as basis. The described steps of the work serve as an overview and background for bioinformatic data analysis. They always should be adapted to current projects in order to achieve the best analysis.

Inhaltsverzeichnis

1 Einleitung 1

2 Sequencing-Methoden 2

2.1 Klassische Methoden 2

2.1.1 Kettenabbruchmethode 2

2.1.2 Methode von Maxam und Gilbert 4

2.2 Moderne Methoden 4

2.2.1 Pyrosequenzierung 4

2.2.2 IonTorrent 5

2.2.3 Illumina Sequenzierung 6

2.3 Methode dritter Generation - Nanopore 8

3 Workflow Pre-Sequencing 9

3.1 Probensammlung und -lagerung 9

3.2 DNA-Extraktion 11

3.3 Agarose Gelelektrophorese 12

3.4 DNA-Quantifizierung und Qualitätsprüfung mittels NanoDrop® oder Quantus™ 13

3.5 16S rRNA target Region und Wahl der Primer 14

4 Workflow Post-Sequencing 16

4.1 Quality Screening 16

4.2 OTU clustering und Zuweisung der Taxonomie 17

4.3 Datensatz aufreinigen und filtern 19

4.4 Statistische Analyse 21

4.5 Alpha- und Beta-Diversität 22

4.6 Darstellung der Ergebnisse 24

5 Anwendungsbeispiel 27

6 Zusammenfassung und Diskussion 33
6.1 Sequencing-Methoden 33
6.2 Workflow Pre-Sequencing 33
6.3 Workflow Post-Sequencing 34
6.4 Anwendungsbeispiel 35
7 Ausblick 36
Literaturverzeichnis VII
Abbildungsverzeichnis XII
Abkürzungsverzeichnis XII

1 Einleitung

Hintergrund von Metagenomprojekten ist einerseits, anhand aktueller Sequencing-Methoden und folgender bioinformatischer Aufarbeitung biologische Daten des Projektes zu gewinnen. Andererseits sollen zusätzlich die Interaktion und Funktion von solchen Biozönosen ermittelt werden. Somit wird die Bioinformatik bei Metagenomprojekten dazu genutzt, Bakterienkulturen oder -gemeinschaften besser zu verstehen. Immer mehr wandelt sich die Bioinformatik von einem unterstützenden und angewandten Bereich zu einer eigenen großen Disziplin der Naturwissenschaft [1, 2]. Die Definition der Bioinformatik hängt vom gewählten Hintergrund ab. Betrachtet man die Bioinformatik von Seiten der Informatik, so lässt sie sich verstehen als Abfolge und Entwicklung passender Algorithmen zur Lösung bestimmter biologischer Aufgaben. Von Seiten klinischer Verwendung der Bioinformatik könnte diese als Transkriptomanalyse definiert werden. Wesentlich gekennzeichnet ist die rapide Entwicklung der Wissenschaft durch neue Methoden der Sequenzierung und durch das große Wachstum an Metagenomik- und Genomprojekten [1, 3].

Ziel dieser Bachelorarbeit ist, den Hintergrund und die Funktion der Schritte bioinformatischer Datenanalysen eines Metagenomprojektes zusammenzufassen. Zum theoretischen Ablauf wird anhand eines Beispielprojektes gezeigt, wie solche Analysen im Detail ablaufen können. Die Arbeit wird unterteilt in vier große Bereiche – den theoretischen Hintergründen: Sequencing-Methoden (Kapitel 2), Workflow Pre-Sequencing (Kapitel 3) und Workflow Post-Sequencing (Kapitel 4); sowie dem praktischen Anwendungsbeispiel (Kapitel 5). Somit dient die vorliegende Arbeit als Übersicht für den Ablauf und die Funktion eines bioinformatischen Workflows im Rahmen einer Untersuchung der 16S rRNA biologischer Gemeinschaften. Grund zur Wahl der 16S rRNA findet sich darin, dass die aktuellsten Workflows auf der Untersuchung dieser Genabschnitte basieren [4]. Dieser Hintergrund kann somit für verschiedenste Projekte als Grundlage genutzt werden. Das Anwendungsbeispiel soll zeigen, wie einzelne Software-Systeme schrittweise Daten aus der Sequenzierung auswerten und für zukünftige Analysen als Hilfestellung dienen.

2 Sequencing-Methoden

Durch die laufenden Entwicklungen und Verbesserungen der Sequenzierung über die letzten 50 Jahre entstanden viele neue Methoden, die sich aktuell in drei Generationen einteilen lassen: die klassischen (*first-generation*), die modernen (*second-generation*) und die Methoden dritter Generation (*third-generation*) [5]. Jede Sequencing-Methode lässt sich anhand bestimmter Charakteristiken einer der Generationen zuteilen, wobei für alle Methoden dieser drei Gruppen gilt, dass die Kosten, sowie der Zeitaufwand mit steigendem Fortschritt abnehmen [5, 6]. In Zukunft wird die Sequenzierung das Werkzeug dafür, den ersten Einblick z.B. in Metagenome zu bekommen und kann als molekulares Mikroskop dienen für verschiedenste Prozesse, wie die Replikation, Transkription oder Translation [7].

2.1 Klassische Methoden

Zu den klassischen Methoden zählen die Kettenabbruchmethode nach Sanger (Kapitel 2.1.1) und die Methode von Maxam und Gilbert (Kapitel 2.1.2). Die Kettenabbruchmethode mittels Abbruch durch Didesoxyribonucleotiden (ddNTPs) diente als Grundlage für die ersten automatisierten Sequencing-Methoden [6, 8].

2.1.1 Kettenabbruchmethode

Die Kettenabbruchmethode beruht auf der Sequenzierung durch Synthese von unterschiedlich langen Fragmenten der template DNA, die in vielen Kopien vorliegt. Die bereits synthetisierten Fragmente setzen sich aus dem Primer am 5'-Anfang und dem ddNTP am 3'-Ende zusammen. Ein Einbau solcher ddNTPs führt zum Abbruch der Synthese durch eine DNA-Polymerase und die ddNTPs sind, Nukleotid-abhängig, mit einem bestimmten Fluoreszenzfarbstoff gekennzeichnet. Anhand der Markierung lässt sich das letzte Nukleotid des DNA-Abschnittes ermitteln und wegen der vielen unterschiedlich langen Fragmente die gesamte DNA-Sequenz bestimmen. Um die Sequenz auszuwerten, werden die synthetisierten Fragmente mittels Gelelektrophorese aufgetrennt. Anhand des Fluoreszenzfarbstoffes der ddNTPs lässt sich das Nukleotid am 3'-Ende definieren. Das gesamte Ergebnis kann zusätzlich

anhand eines Spektrogramms dargestellt werden. Im Gel wandern die verschieden langen DNA-Fragmente unterschiedlich schnell, wobei das kürzeste am unteren Ende der Auftrennung liegt und das längste am oberen Ende. Somit wird die zu analysierende Sequenz und die Abfolge der ddNTPs von unten nach oben gelesen [6]. Der Ablauf der Sequenzierung nach Sanger wird in Abbildung 1 grafisch dargestellt.

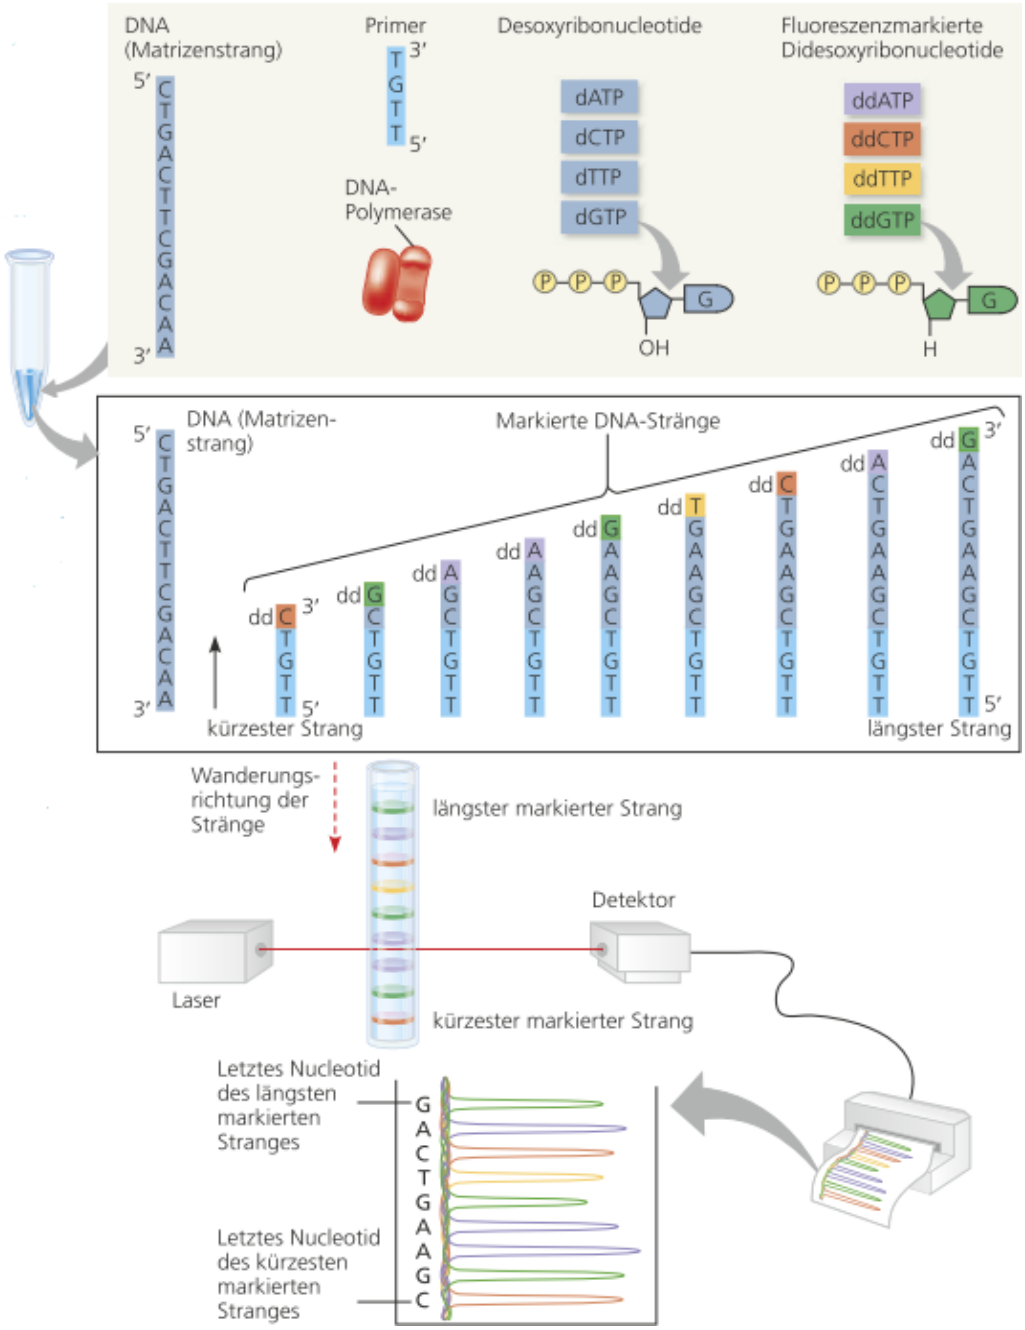

Abbildung 1: Ablauf der Kettenabbruchmethode in Anlehnung an [6]. Unterschiedlich lange DNA-Fragmente werden synthetisiert. Wird anstatt eines dNTPs ein markiertes ddNTP eingebaut erfolgt Abbruch der Synthese. Mittels Gelelektrophorese werden die Fragmente aufgetrennt und die Sequenz abgelesen [6].

2.1.2 Methode von Maxam und Gilbert

Bei der chemischen Spaltungs-Methode von Maxam und Gilbert wird zur Auswertung der DNA-Fragmente, wie bei der Kettenabbruchmethode (Kapitel 2.1.1), Gelelektrophorese verwendet. In ihren Ansätzen unterscheiden sich die beiden klassischen Methoden jedoch wesentlich. Maxam und Gilbert nutzten erstmals Chemikalien um die markierte DNA zu brechen [5]. Die Sequenz des markierten DNA-Moleküls wird durch Aufbrechen von Nukleinbasen (A, T, G, C) mit spezifischen Chemikalien ermittelt. Meist wird die DNA entweder am 5‘- oder 3‘-Ende radioaktiv markiert. Die spezifischen Reagenzien bewirken eine Abspaltung der Basen. Jede Chemikalie, basen-spezifisch, wird separat in vier verschiedenen Ansätzen angewendet und nach der Abspaltung durch Gelelektrophorese aufgetrennt und anschließend die Sequenz abgelesen. Limitiert ist dieses Verfahren nur anhand der möglichen Auftrennung eines Polyacrylamid-Gels bei der Gelelektrophorese [9].

2.2 Moderne Methoden

Drei der wichtigsten modernen Methoden sind die Pyrosequenzierung (Kapitel 2.2.1), IonTorrent (Kapitel 2.2.2) und die Illumina Sequenzierung (Kapitel 2.2.3). Solche Methoden „nächster Generation“ (NGS) haben sich im Laufe des letzten Jahrzehnts etabliert und basieren nicht mehr auf der klassischen Kettenabbruchmethode, der Sanger-Methode. Die NGS-Methoden beruhen auf der parallelen Sequenzierung durch Synthese und sind aktuell die am Meisten verwendeten Sequencing-Methoden. Vorwiegend werden sie genutzt um große Proben wie bei Metagenomprojekten zu analysieren, da durch den parallelisierten Ablauf 1000 bis 100.000 DNA-Fragmente innerhalb kürzester Zeit übersetzt werden können [6].

2.2.1 Pyrosequenzierung

Im Jahr 2005 wurde durch das Unternehmen 454 Life Sciences die Pyrosequenzierung präsentiert [8]. Die verwendeten Library-Moleküle werden mit Hilfs-Sequenzen an kleine Kugeln gebunden. Mit diesen findet die Amplifikation durch Emulsions-PCR (emPCR) statt [5]. Diese Art von PCR wird in einer Öl-Wasser-Emulsion durchgeführt, wobei zusätzlich zum Molekül die

benötigten Reagenzien für eine Vervielfältigung vorliegen. Einer der zwei verwendeten Primer befindet sich ebenso in dieser Emulsion, der andere bindet auf der Kugel [7]. Nach optimalem Ablauf befinden sich nach der emPCR viele Kopien eines einzigen Moleküls auf einer Kugel, wobei zahlreiche verschiedene Kugeln vorliegen. Diese Kugeln werden über eine Reaktionsplatte gewaschen und dort abgelagert. Die Platte besteht aus winzigen Vertiefungen, die jeweils Platz für eine Kugel bieten. Die Sequenzierung erfolgt indem Enzyme, Luciferasen, und dNTPs auf die Platte aufgetragen werden. Liegt ein passender Baustein vor, wird dieser eingebaut, durch die Reaktion Pyrophosphat freigesetzt und mittels des Enzyms ein Lichtsignal erzeugt. Das Signal wird durch einen Sensor am Boden der Reaktionsplatten detektiert. Die Reihenfolge der eingebauten dNTPs muss bekannt sein, um das Lichtsignal dem richtigen Baustein zuzuordnen. Angewendet wird die Pyrosequenzierung bevorzugt für bisher nicht analysierte Metagenome und DNA-Abschnitte [5, 10].

2.2.2 IonTorrent

IonTorrent, eine Plattform des Unternehmens Thermo Fisher Scientific Inc., basiert auf der Sequenzierung durch Synthese und Detektion der Basen mittels pH-Messung. Dies ist eine Feststoff-Messung der freigesetzten Wasserstoffionen während dNTPs mittels DNA-Polymerase angebaut werden [7, 8, 11]. Wie bei der Pyrosequenzierung (Kapitel 2.2.1) muss das Signal verstärkt werden, indem mit einer emPCR die template DNA vervielfältigt wird. Die Laufzeit der IonTorrent Sequenzierung gegenüber der Illumina Sequenzierung (Kapitel 2.2.3) ist wesentlich kürzer [7, 8]. Methode der IonTorrent Sequenzierung ist, dass auf einer Kugel oder Perle die template Sequenzen erzeugt werden. Dies ist möglich mittels emPCR und erfolgt gleich wie bei der Pyrosequenzierung (Kapitel 2.2.1). Nach Ablaufen der Amplifikation liegen eine Menge verschiedener Kugeln mit unterschiedlichen Fragmenten vor, die auf einem Halbleiterchip abgelagert werden. Solch spezifische Chips enthalten kleine Reaktionskammern mit Schächten und pH-Sensoren. Auf dem Chip plus den Kugeln werden nach und nach, in vorbestimmter Reihenfolge, dNTPs hinzugefügt. Bei Zugabe der dNTPs werden chemische Signale in Form von H^+-Ionen abgegeben, in digitale Information umgewandelt und somit die Sequenz detektiert. Die Reihenfolge der dNTPs

muss definiert und bekannt sein, da anhand der abgegebenen H^+-Ionen nicht bestimmt werden kann um welches Nukleotid es sich handelt, sondern nur, ob das zugegebene Nukleotid an der bestimmten Stelle vorliegt und für die pH-Veränderung verantwortlich ist [7]. Thermo Fisher Scientific Inc. verwendet bei dieser Art der Sequenzierung nur nicht-markierte, natürliche Reagenzien [11].

2.2.3 Illumina Sequenzierung

Einen wichtigen Anteil der NGS-Methoden nimmt die Illumina Sequenzierung ein. Diese basiert auf dem Nachweis von (reversibel) blockierten Terminator-Nukleotiden durch Markierung mittels Fluoreszenz, sowie Sequenzierung durch Synthese des komplementären DNA-Strangs [8, 12]. Instrumente der Illumina, wie MiniSeq oder MiSeq, sind preiswert, benutzerfreundlich und bieten einen niedrigen bis mittleren Durchsatz [8]. Die Sequenzierung findet Anwendung, liegen bereits Vergleichsequenzen der analysierenden DNA vor. Abhängig vom Illumina-System ist die optische Oberfläche („flow-cell“) in eine verschiedene Anzahl an Bahnen unterteilt. Beim MiSeq-System gibt es eine Bahn, HiSeq2500 hat zwei und HiSeq2000/HiSeq2500 können acht Bahnen haben [7].

Bei der Illumina Sequenzierung wird die Synthese der DNA-Stränge betrachtet. Die Sequenzierung findet auf einer optischen Oberfläche statt. Begonnen wird mit dem Laden der aufgebrochenen dsDNA-Moleküle (double-strand), den ssDNA-Molekülen (single-strand), auf die Oberfläche (Schritt 1 in Abbildung 2). Hier binden die Moleküle mit Oligonukleotiden, die als Primer dienen, und vereinigen sich zu einer Matrize, die als Vorlage zum Kopieren der Moleküle benötigt wird (Schritt 2 in Abbildung 2). Nach Vervielfältigung dieser DNA-Fragmente werden die ursprünglichen Moleküle entfernt. Die an der optischen Oberfläche angehängten Fragmentkopien nutzt man dazu, einen Cluster von identischen Vorlagen bei der Amplifikation zu erzeugen. Das ist möglich durch ständige Abwechslung dreier Puffer. Diese Puffer stehen spezifisch für Denaturierung, Annealing und Extension bei einer Temperatur von circa 60 °C. Während dieser Schritte hybridisieren die vielen Kopien mit komplementären Oligonukleotiden und bilden eine Brückenstruktur (Schritte 3 bis 5 in Abbildung 2). Abschließender Schritt ist, einen Strang der vorliegenden dsDNA zu entfernen (Schritt 6 in Abbildung 2), sowie die 3'-Enden mit ddNTPs zu

blockieren. Das ist notwendig, da ansonsten offene Enden falscherweise als Primer erkannt werden könnten [5, 7]. Während der sich wiederholenden Zyklen bei der Sequenzierung baut man fluoreszenzmarkierte dNTPs ein. Jedes Nukleotid ist spezifisch markiert, um eine bestimmte Base zu repräsentieren. Weiters dienen sie als reversible Terminatoren. Nach Einbau eines dNTPs stoppt die Synthese und kann erst fortsetzen, wenn die fluoreszierende Gruppe des Moleküls abgespalten wird. Der Ablauf der Schritte 1 bis 6 von Abbildung 2 ist notwendig, um ein starkes Signal zu erzeugen, welches vom Detektor registriert werden kann. Der Einbau von dNTPs erfolgt solange, bis die komplette DNA synthetisiert ist [7].

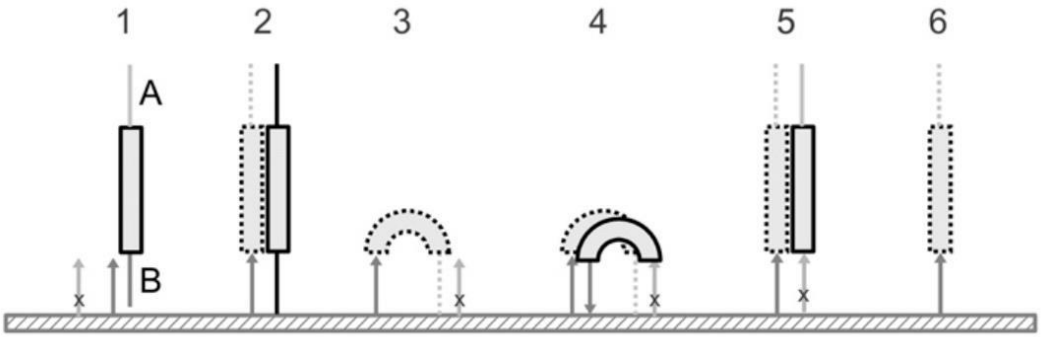

Abbildung 2: Erstellung der template Moleküle bei Illumina Sequenzierung mittels Brücken-Amplifizierung. In Schritt 1 bindet die ssDNA mit passender Sequenz (B) an die komplementären Oberflächenprimer. Es bildet das Vorlagemolekül (Schritt 2) für die Amplifikation (Schritte 3 bis 5). Schritt 6 stellt die Entfernung eines Stranges der dsDNA dar, sowie das Blockieren der 3‘-Enden mit ddNTPs [7].

Um Erkenntnis über die Vielfalt mikrobieller Gemeinschaften zu bekommen, verwendet man standardmäßig 16S rRNA Abschnitte für die Sequenzierung [4]. Die wichtigste Plattform dafür ist das System der MiSeq Illumina Sequenzierung [13]. Vorteile der 16S rRNA Amplicon Sequenzierung sind, dass für eine erfolgreiche Sequenzierung kleine Mengen der Proben ausreichen, sowie keine Sequenzen als Referenz notwendig sind. Folglich findet diese Sequencing-Methode vielseitige Anwendung bei Metagenomprojekten [13–15]. Die Methode der 16S rRNA Illumina Amplicon Sequenzierung erfolgt nach dem gleichen Prinzip wie die grundsätzliche Durchführung der Illumina Sequenzierung (in diesem Kapitel zu Beginn erklärt). Häufig werden Sequenzen mit einer Länge von 250 bp erzeugt und paired-end Sequenzierung angewendet. Nutzt man

paired-end bei Illumina, wird ein Fragment zweimal, vom 5'-Ende und 3'-Ende des Stranges, abgelesen. Dadurch werden hochwertige Datensätze erzeugt [13].

2.3 Methode dritter Generation - Nanopore

Der aktuellste Fortschritt in der Entwicklung der Sequenzierung umfasst die Methoden dritter Generation. Der neue state of the art liegt in der Sequenzierung der DNA ohne Denaturierung oder Amplifizierung, so auch bei der Nanopore-Methode [6]. Somit unterscheiden sich Methoden dritter Generation von den NGS-Methoden (Kapitel 2.2) dadurch, dass Fragmente der DNA nicht über Sequenzierung durch Synthese übersetzt, sondern die Stränge direkt, ohne Aufbrechen oder Zerlegen, sequenziert werden [5, 6].

Seit dem Jahr 2012 wird die Nanopore Sequencing-Methode angewandt und zeigt für die weitere Zukunft großes Potential. Es gibt keine Begrenzung der Länge der zu sequenzierenden DNA und wird das Verfahren auf einem Chip durchgeführt, lässt sich die Sequenzierung parallelisieren und der Zeitaufwand verringern. Grundlage der Nanopore Sequencing-Methode ist, dass an eine mit einer Nanopore versehenen Membran, ein Spannungsunterschied angelegt wird. Durch die Differenz entsteht ein Ionenfluss an der Pore, wobei die Elektrolyt-Ionen anhand von Elektrophorese durch die Pore bewegt werden und ein Signal des Ionenstroms erzeugt wird [16, 17]. Die zu analysierende DNA wird linear durch diese Pore gezogen. Die Anwesenheit des DNA-Strangs in der Nanopore blockiert kurzzeitig (im Nanosekunden-Bereich) den gesamten Stromfluss. Durch diese Unterbrechung, die basenspezifisch unterschiedlich lange dauert, kann die Sequenz mithilfe eines Sensors erfasst werden. Einziger Punkt der möglichen Ungenauigkeit dieser Methode ist das Auflösungsvermögen des messenden Sensors. Die Technik steht noch in der Entwicklung und soll durch praktische Anwendungen kontinuierlich verbessert werden [16].

3 Workflow Pre-Sequencing

Bei Metagenomanalysen und ähnlichen Projekten, die dazu dienen, biologische Gemeinschaften zu analysieren, gibt es einige Faktoren, die bei den einzelnen Schritten beachtet werden sollten. Das ist wichtig, um Fehler - zufällige oder systematische - zu vermeiden. Zum Workflow Pre-Sequencing zählen alle Arbeitsschritte, die vor dem Sequenzieren der Proben erforderlich sind. Im Folgenden wird der Workflow Pre-Sequencing in fünf Bereiche eingeteilt und zu jedem dieser die möglichen Funktionen und Anwendungen beschrieben, um oben genannte Fehler zu vermeiden [18]. Abhängig von der Sequencing-Methode gibt es Differenzen im Ablauf der Probenaufbereitung [19]. Folgender Workflow spezifiziert sich auf die Analyse mikrobiologischer Gemeinschaften anhand der 16S rRNA [4, 18].

3.1 Probensammlung und -lagerung

Probensammlungen, die dazu dienen, Daten aus der Umwelt mittels Sequencing-Methoden zu analysieren, können zu Verfälschungen und Fehlern führen, die von Beginn an bekannt sind und dadurch vermieden werden sollen. Allgemein hängen die Probenmengen und die Art der Probe davon ab, was genau untersucht werden soll [4, 18]. Art der Probe bedeutet, dass unterschiedliche Proben separat oder als homogene Mischprobe großer Mengen gelagert werden [18]. Handelt es sich um Feststoffbodenproben, kann eine unterschiedliche Bodenbeschaffenheit, eine Heterogenität, auftreten [18]. Für Bodenproben ist somit die Homogenisierung ein großer Einflussfaktor, da in solchen oft viele unterschiedlich große Partikel enthalten sind [4]. Die Feinfraktion der Bodenprobe wird bei Untersuchungen von Feststoffböden zur Analyse herangezogen. In dieser Fraktion handelt es sich ausschließlich um Partikel, die kleiner als 2 mm sind und in der Probenaufbereitung gesiebt werden [20]. Aufgrund der vorliegenden Komplexität läuft aktuell zu Wasserproben eine Langzeitstudie, die sich damit beschäftigt optimale Probensammlungen zu entwickeln. Eine Möglichkeit der Probennahme von Wasserproben ist die stationäre Probensammlung. Hierbei wird ein geographischer Punkt als Probenort definiert, und nur an diesem Punkt werden

Proben gesammelt. Problem ist, dass nicht eindeutig geklärt werden kann, warum eine Änderung der mikrobiellen Gemeinschaft möglich ist und was die Auslöser dafür sind. Möglich ist einerseits eine Veränderung der Gemeinschaft im Wasser an sich, andererseits kann auch durch den Wasserfluss eine Gemeinschaft durch eine andere beeinflusst oder verdrängt werden. Zweite Möglichkeit der Probensammlung für Wasserproben erfolgt durch Bojen. Dieser Ansatz nennt sich Lagrange-Probennahme. Mit solchen Bojen werden Proben von Wassermassen gesammelt. Nachteil der Methode ist, dass nach wenigen Wochen eine Mischung unterschiedlicher Wassermassen auftritt, die mit der ursprünglichen Probe nicht mehr gleichzusetzen ist [18].

Die Frequenz der Probensammlungen ist an die aktuelle Forschungsfrage und der zu untersuchenden Lebensgemeinschaft anzupassen. Liegen viele Proben vor, ergibt sich eine gute Repräsentativität [18].

Nach der Probensammlung findet die Probenlagerung statt. Bei idealer Lagerung treten Veränderungen, wie Degradation und Schäden an der DNA, sowie Überwachsen der Bakterien, nicht auf. Handelt es sich um Bakterien, werden diese schnellstmöglich inaktiviert. Die DNA soll so wenig wie möglich beschädigt werden, um keinen Verlust der Daten zu riskieren, welche die Sequenzierungs-Ergebnisse erheblich beeinflussen können. Häufig werden die Proben eingefroren, da die DNA-Extraktion nicht sofort nach Probennahme stattfindet [4, 18]. Wird ständig eingefroren und wieder aufgetaut, muss beachtet werden, dass die DNA und Zellen der Bakterien Schaden davontragen können [18]. Optimale Lösung erzielt schnelles Einfrieren der Proben auf -80 °C [4, 21, 22]. Pollock et al. empfehlen sofortige DNA Extraktion nach der Probensammlung. Da dies oft aufgrund von fehlenden Möglichkeiten am Probenahmeort nicht möglich ist, sollten die Proben unter gleichbleibenden Umweltbedingungen gelagert werden, bis die Extraktion stattfindet [4]. Erfolgreiche Alternativen zum sofortigen Einfrieren sind etwa das Nutzen probenabhängiger Konservierungsmedien oder Puffer, sowie die Lagerung unter anderen Konditionen, etwa bei 4 °C oder Raumtemperatur [22]. Das Lagern in Medien hängt von der Ausstattung der zur Verfügung stehenden Labore ab [18].

3.2 DNA-Extraktion

Bei der DNA-Extraktion werden die Zellen der gesammelten Proben aufgeschlossen [18]. Methoden zum Aufbruch der Zellen sind die mechanische bzw. chemisch-enzymatische Lyse oder Phenol-Chloroform Extraktion. Die Extraktion ist abhängig vom vorausgehenden Schritt, der Probensammlung (Kapitel 3.1). Ziel der DNA-Extraktion ist, maximale Ausbeute und beste Qualität der zu analysierenden biologischen Gemeinschaft zu erreichen [4].

Anhand der Probenahme liegen unterschiedliche Mengen an Ursprungsmaterial vor, die dazu führen, dass nur bestimmte Extraktions-Methoden angewendet werden können [4, 19, 23]. Die am meisten verwendeten Extraktions-Kits zeichnen sich durch einfache Bedienung, kurze Durchführungszeit und durchschnittliche Leistung aus. Nachteil dieser Kits ist die geringe Probenmenge, die extrahiert werden kann (0,15-0,5 g). Ebenso abhängig ist der Erfolg der Extraktion von der Umgebung des Probenahmeortes. Physikalische, chemische oder biologische Eigenschaften des Probenmaterials tragen dazu bei, wie effektiv die Beseitigung von Verunreinigungen und der Aufschluss der Zellwände ist. Wichtig bei der DNA-Extraktion ist, dass alle Zellen der Lebensgemeinschaft aufgeschlossen werden, da ansonsten bestimmte Organismen im Gesamtbild nach der Sequenzierung nicht vertreten wären und daraus falsche Ergebnisse entstehen würden [18]. Es ist zu beachten, dass verschiedene Zellen unterschiedlich auf die Lyse ansprechen. Betrachtet man gram-positive und gram-negative Bakterien, sind jene mit dickerer Zellwand (gram-positive) resistenter gegenüber dem Aufschluss [4]. Verunreinigungen, die nicht entfernt werden, führen zu schlechtem Ablauf der Amplifikation der DNA und daraus zu möglichem Verlust einzelner Proben. Verunreinigungen umfassen organische Säuren oder andere biologische Moleküle [18].

Beispiel für ein Extraktionskit das für Bodenproben in Frage kommt ist das NucleoSpin® Soil Kit hergestellt vom Unternehmen Macherey-Nagel [23]. Der Ablauf einer DNA-Extraktion wird am Beispiel dieses Kits dargestellt. Das NucleoSpin® Soil Kit eignet sich besonders für Bakterien (gram-positiv und gram-negativ), Algen (in Sediment-, Schlamm-, oder Bodenproben), Pilze,

Archaea und weitere diverse Bodenproben. Die Extraktion findet in Röhrchen statt und optimale Menge an Ausgangsmaterial sind 200-250 mg [24].

Die Extraktion mit dem NucleoSpin® Soil Kit wird in zehn Schritte eingeteilt:

- Probenvorbereitung
- Anpassung der Bedingungen für optimale Lyse
- Lyse der Zellen
- Fällung unerwünschter Stoffe
- Filterung des Lysats
- Anpassung der Bedingungen für Bindung der DNA an die Membran
- Bindung der DNA an die Membran
- Waschen der Membran
- Trocknen der Membran
- Auswaschen der DNA

Die Probe kann nun weiterverwendet werden, um die extrahierte DNA zu quantifizieren und die Qualität zu überprüfen vor der Amplifikation und Sequenzierung [24].

3.3 Agarose Gelelektrophorese

Liegen unterschiedlich lange DNA Fragmente in einer Probe vor, können diese mittels Gelelektrophorese aufgetrennt und sichtbar gemacht werden [3]. Der Nutzen der Agarose Gelelektrophorese im Workflow Pre-Sequencing ist, zu überprüfen, wie erfolgreich die DNA-Extraktion abgelaufen ist, sowie die Größenbestimmung der entstandenen Fragmente [6, 19]. Bei einer Agarose Gelelektrophorese handelt es sich beim verwendeten Gel um das Polymer Agarose. Dieses Gel wird als molekulares Sieb genutzt, um DNA-Fragmente anhand derer verschiedenen Größen aufzutrennen. Es gibt auch weitere Arten von Gelen mit anderen Polymeren, z.B. Polyacrylamid, die für Moleküle kleinerer Größe zur Auftrennung besser geeignet sind. Neben der Auftrennung nach Größe, kann auch nach Eigenschaften, wie der elektrischen Ladung oder weiteren physikalischen Merkmalen, differenziert werden.

Funktion der Elektrophorese ist, dass die zu untersuchenden Proben mit DNA-Molekülen in Taschen pipettiert werden, die am oberen Ende des Gels liegen. Das Gel selbst liegt in einer Kammer, an welcher zwei Elektroden angebracht sind. Am einen Ende, an dem sich die Taschen befinden, wird die Kathode (Minuspol) und am gegenüberliegenden Ende die Anode (Pluspol) angebracht. Abbildung 3 zeigt den Aufbau einer Agarose Gelelektrophorese [6].

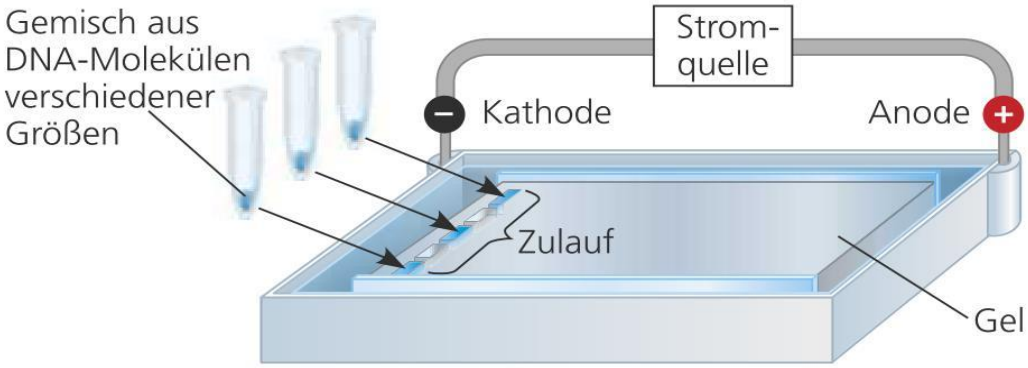

Abbildung 3: Aufbau der Apparatur einer Gelelektrophorese. Das in einer Kammer liegende Gel enthält Taschen zur Beladung der Fragmente. An beiden Enden sind für die Auftrennung Elektroden angebracht [6].

3.4 DNA-Quantifizierung und Qualitätsprüfung mittels NanoDrop® oder Quantus™

Nach der Probenaufbereitung (Kapitel 3.1-3.3) erfolgt die Quantifizierung und Qualitätskontrolle. Die optimale Konzentration der DNA führt zu einem idealen Ablauf der Sequenzierung. Zu hohe Konzentrationen führen zu Überlappungen der Sequenzfragmente, während zu niedrige Konzentrationen dazu führen, dass die mögliche Leistung der Sequenzierinstrumente nicht voll ausgenutzt werden würde, und wiederum höhere Kosten für die Analyse verursachen. Stand der Technik ist, dass die Konzentration der DNA anhand Fluorometrie durch spezielle Fluoreszenzfarbstoffe gemessen wird. Erhaltene Einheit ist die Massenkonzentration (ng/µl). Die Konzentration kann durch die bekannte Fragmentlänge aus der Gelelektrophorese in nM, die molare Konzentration, umgerechnet werden. Vorteil dieser Methoden ist, dass die DNA von anderen Verbindungen, wie organische, Proteine oder Salze, unterschieden werden kann [19]. Geräte zur Quantifizierung sind z.B. NanoDrop® und Quantus™. Bei NanoDrop® Fluorometrie und Spektralphotometrie Kits des Unternehmens

Thermo Fisher Scientific werden nur kleine Volumina an Proben benötigt, um Messungen der Konzentration durchzuführen. Daraus ergeben sich Vorteile wie geringe Mengen an benötigten Reagenzien, sowie die Möglichkeit der parallelen Analyse vieler Proben [25]. Für die Quantifizierung ist eine Standardgerade erforderlich [26]. Die Quantifizierung der DNA durch den Quantus™ Fluorometer der Firma Promega folgt einem sehr empfindlichen Fluoreszenznachweis. Das Gerät lässt sich einfach bedienen und Standardeinstellungen können selbst optimiert und personalisiert werden [27]. Die Spektralphotometrie umfasst alle Ansätze der quantitativen Analyse anhand von Licht. Ein Spektralphotometer misst die Konzentration der DNA anhand ihrer Absorption, wird diese mit Licht bestrahlt [28]. Die Fluorometrie stellt alle Methoden dar, die anhand von Fluoreszenz die Konzentration bestimmt [29].

3.5 16S rRNA target Region und Wahl der Primer

Im Anschluss zur DNA-Quantifizierung und Prüfung der Qualität (Kapitel 3.4) werden vor Ablauf der Sequenzierung die zu analysierenden Abschnitte, die target Regionen der DNA, mittels PCR amplifiziert [18]. In der 16S rRNA gibt es bestimmte Abschnitte, die sich von Bakterium zu Bakterium unterscheiden. Diese Abschnitte nennt man hypervariable Regionen. In der 16S rRNA kommen neun dieser Regionen vor und werden mit V1-V9 bezeichnet. Will man Bakterien untereinander differenzieren und werden diese hypervariablen Sequenzabschnitte betrachtet, muss dies immer mehr als für eine Region erfolgen. Grund dafür ist, dass eine einzelne Region nicht genutzt werden kann, um unter allen Bakterienarten eine Art spezifisch zu unterscheiden. Es sind Kombinationen der hypervariablen Regionen notwendig [30, 31]. Für jede Domäne (Bakterien, Eukaryoten, sowie Archaeen) sind die hypervariablen Regionen bestimmt [32]. Unter konservierte Regionen in 16S rRNA Genabschnitten versteht man Sequenzen, die dieselbe Abfolge haben. Hypervariable Regionen werden von konservierten umgeben [33]. Bei Bakterien werden die hypervariablen Regionen (meist V1-V3 oder V3-V5) sequenziert [34]. Analysiert man Pilze, werden Internal Transcribed Spacer (ITS) Regionen sequenziert [35]. Diese Regionen sind spezifische Nukleotidabfolgen der rRNA, anhand der die bestmögliche Unterscheidung von Pilzarten erfolgt [36, 37].

Primer sind wichtige Moleküle in der PCR. Mit ihrer angepassten Sequenz binden sie an der template DNA und ermöglichen der DNA Polymerase die Synthese des Stranges. Ein Primer hat eine Länge zwischen 15-30 bp [6, 18]. Wäre der Primer kürzer als 15 bp, würde dieser nicht nur an die gewünschten Moleküle binden, sondern an viele weitere. Wäre er länger als 30 bp würde er zu spezifisch für die Sequenz sein und nur an wenige Moleküle binden. Mit der PCR wird die Zielregion pro Durchlauf des Zyklus verdoppelt. Zeigt die DNA nun keine Komplementarität mit den Primern, wird die Sequenz nicht vervielfacht und es ergibt sich ein falsches Bild der Biozönose. Abhilfe dazu gibt es, indem verschiedene Primer genutzt werden, die sich minimal unterscheiden. Die Wahl der Primer beeinflusst erheblich das Ergebnis und die Qualität der PCR, da bei der Verwendung unterschiedlicher Primer, ebenso unterschiedliche Profile entstehen, obwohl es sich um gleiche Proben handelt [18, 38]. Größte Fehlerquellen der PCR sind einerseits eine falsche Paarung der Primer, andererseits die Bildung von chimären Sequenzen während der Amplifizierung. Eine falsche Paarung führt zu Störung der Reaktion. Chimäre zeichnen sich dadurch aus, dass Moleküle aus unterschiedlichen Sequenzen bestehen, die sich während der PCR zusammenschließen. Es entstehen somit neue Abfolgen von Sequenzen, die in der ursprünglichen Probensammlung nicht vorhanden waren. Grund dafür ist, dass sich während der Kettenreaktion viele der zu vervielfachenden Sequenzen sehr ähneln und neue Sequenzen immer wieder als Vorlage verwendet werden [18].

Mithilfe verschiedener Computerprogramme können ideale Primer ermittelt werden und diese Programme helfen, die Primer zu bewerten. Beispiele für solche Computerprogramme sind etwa PrimerProspector oder DegePrime [18]. Mit der frei zugänglichen Software PrimerProspector werden Primer optimiert und analysiert. Die Primer selbst konstruiert das Programm *de novo* anhand verschiedener Sequenzvergleiche [38]. Das Programm DegePrime sucht anhand eines Algorithmus optimale Primer. Hughert et. al. (Quelle [39]) betonen, dass der neu entwickelte Algorithmus für zufällige Kombinationen der Primer sorgt, die für ideale Anlagerung an die template DNA geeignet sind [39].

4 Workflow Post-Sequencing

Arbeitsschritte, die nach der Sequenzierung der Proben anfallen, lassen sich dem Workflow Post-Sequencing zuordnen. Die Rohdaten aus der Sequenzierung werden in diesem Prozessablauf mithilfe verschiedener Software-Tools zusammengefasst, gefiltert, analysiert und zuletzt visuell dargestellt. Unabhängig von der verwendeten Software laufen die Arbeitsschritte meist in derselben Reihenfolge ab und behandeln die gleichen Fehler und Probleme. Dies trägt dazu bei, ein aussagekräftiges Ergebnis einer Untersuchung von Metagenomen oder weiteren diversen biologischen Gemeinschaften zu erlangen.

4.1 Quality Screening

Das Quality Screening dient dazu, fehlerhafte Sequenzen, entstanden aus der Sequenzierung, zu entfernen. Typus der Fehler hängt von der gewählten Sequencing-Methode ab [40]. Betrachtet werden im Quality Screening etwa Chimäre, Homopolymere oder ambiguous reads (Ambigs). Neben diesen Sequenzierfehlern gibt es drei weitere große Fehler, die während der PCR sowie der Sequenzierung entstehen können. Diese sind Deletionen (zuvor vorhandene Basen werden ausgelassen), Substitutionen (Basen werden durch andere ersetzt) und Insertionen (zuvor nicht vorhandene Basen werden eingebaut). Abhängig von der Sequencing-Methode kommen diese Fehler spezifisch oft vor und können mit verschiedenen Hilfsmitteln und Werkzeugen vermieden werden [18, 40].

Die durch die PCR entstandenen chimären Sequenzen werden im ersten Schritt des Workflow Post-Sequencing entfernt. Sie entstehen durch Zusammensetzung zweier oder mehrerer ursprünglicher Sequenzen und bilden eine neue Sequenz. Erkannt werden sie entweder anhand einer Kontrolle durch Datenbanken oder Vergleiche mit Sequenzen im Datensatz [18]. Methoden dazu sind die Verwendung von Algorithmen wie UCHIME oder VSEARCH [41, 42]. Mit UCHIME und VSEARCH können Chimäre bestimmt werden [41, 42]. Unabhängig von Sequenzabschnitten lassen sich mithilfe von UCHIME Chimäre auch in kurzen Sequenzen eindeutig identifizieren. Für eine

erfolgreiche Bestimmung muss eine Datenbank bereitgestellt sein. Der Algorithmus UCHIME erlaubt die Kombination von Genauigkeit und schneller Durchführung der Analyse [41]. VSEARCH ist ein frei zugängliches Programm, das mittels optimierter Algorithmen metagenomische Daten verarbeitet. Es kann ebenso zur Findung von Chimären genutzt werden. Vorteile von VSEARCH sind dieselben wie bei UCHIME, Genauigkeit und Schnelligkeit [41, 42]. Die aktuell am meisten verwendete Methode ist VSEARCH.

Homopolymere sind Sequenzen, die in bestimmter Abfolge der Nucleotide nur eine Base in Reihe enthalten. Durch mögliche Entstehung solcher Abschnitte während der Sequenzierung, wird der Datensatz nach der Sequenzierung auf Homopolymere überprüft. Gefundene Sequenzen mit Homopolymer-Abschnitten werden gelöscht. In den bioinformatischen Analyse Softwares QIIME und mothur kann selbst die Länge der Homopolymere definiert werden, welche herausgenommen werden sollen [43–46].

Ambigs können nach der Sequenzierung in Abschnitten vorkommen. Es bedeutet, dass an einer Stelle in der Sequenz die Base nicht korrekt identifiziert wurde und kennzeichnet sich durch ein N (anstatt der Basenkürzel A, T, G, C). Aufgrund der Annahme, dass Ambigs Sequenzierfehler sind, werden sie aus dem vorliegenden Datensatz gefiltert [47]. Nutzt man die Software mothur, werden Ambigs durch Aufruf eines bestimmten Befehls gelöscht (Kapitel 5) [43].

Durch die Plattform Pollux lassen sich fehlerbehaftete Sequenzen korrigieren. Die Plattform eignet sich als Korrektursoftware bei Metagenomprojekten und ist von der Sequencing-Methode unabhängig [40].

4.2 OTU clustering und Zuweisung der Taxonomie

OTU (Operational Taxonomic Unit) clustering bedeutet, dass die Sequenzen nach deren Ähnlichkeit gruppiert und anhand spezifischer Sequenzen zugeordnet werden [4, 18]. Durch das Clustering ist es möglich, falsche Sequenzen, entstanden durch PCR und Sequenzierung, zu entfernen. Mit dem Schritt des OTU clustering werden die unterschiedlichen Sequenzen in reale biologische Vielfalt eingeteilt [18].

Die Zuweisung erfolgt nach drei möglichen Verfahren, dem open oder closed reference, sowie *de novo* clustering. Unter closed reference clustering versteht sich, dass eine Datenbank vorliegt, mit der die Sequenzen verglichen werden und diese anhand der Übereinstimmung mit Sequenzen aus der Datenbank bestimmte Cluster, und somit OTUs, zugeordnet werden. Die Sequenzen müssen eine hohe Gleichheit aufweisen [18, 48, 49]. Ist dies nicht der Fall, werden sie nicht weiterverwendet und aus dem Datensatz entfernt. Das open reference clustering verläuft nach gleichem Prinzip wie das closed reference clustering und nutzt eine Datenbank zum Vergleich. Liegt keine Übereinstimmung vor, werden die Sequenzen bei diesem Verfahren jedoch nicht verworfen, sondern nach *de novo* Ansätzen eingeteilt [18, 50]. Erfolgt die OTU Zuweisung anhand open reference clustering, können große Datensätze anhand von Subsampling die Sequenzen zusätzlich vorgruppieren. Es werden die Sequenzen mit einer Datenbank verglichen und anhand dieser in Untergruppen gegliedert. Subsampling in diesem Schritt des Workflows führt zu kürzeren Laufzeiten und ermöglicht es, riesige Datensätze zu analysieren [49].

Eine Studie über die Bewertung des open und closed reference clustering durch Westcott und Schloss (2015) (Quelle [50]) zeigt, dass grundsätzlich *de novo* Ansätze die idealen Methoden für OTU clustering sind.

Es gibt zwei Möglichkeiten, *de novo*-Ansätze einzuteilen. Beim einen Verfahren, dem heuristischen, wird eine Sequenz in der Clustergruppe aufgenommen, wenn es mit einer weiteren Sequenz aus der OTU eine bestimmte Verwandtschaft besitzt. Wird dieser Ansatz verwendet, ergeben sich umfangreiche OTUs mit großer Heterogenität. Bei Pilzen, die sich rasch entwickeln findet das heuristische *de novo* clustering Anwendung, ansonsten wird es kaum genutzt [48]. Beim anderen Verfahren, dem hierarchischen, muss eine Sequenz die Ähnlichkeit zu allen Sequenzen haben, um in denselben Cluster zu kommen. Es entstehen eine Menge verschiedene OTUs, die oft nicht der Wahrheit der Gemeinschaft entsprechen und diese somit meist überbewerten. Möglich ist auch eine Kombination beider. Ist das der Fall, spricht man von mittlerer Verknüpfung, bei welcher eine Sequenz nur eine

durchschnittliche Ähnlichkeit zu den anderen aufweisen muss, um dem Cluster zugeteilt zu werden [18].

Bei Prokaryoten wird beim OTU clustering häufig auf eine Ähnlichkeit der biologischen Gemeinschaft von 97 % geprüft. Dieses Ähnlichkeitsmaß ist bei Eukaryoten oft höher angesetzt, hängt stets von der Forschungsfrage ab und kann von Projekt zu Projekt unterschiedlich sein [18, 48].

Nach clustering der OTUs erfolgt die Zuweisung dieser der Taxonomie. Dieser Schritt gibt Kenntnis über die einzelnen Taxa, woraufhin das Ergebnis der Zuordnung mit anderen Studien und Ergebnissen verglichen werden. Hierzu gibt es verschiedene Ansätze, die verwendet werden können und auf verschiedenen Datenbanken beruhen. Software, wie mothur oder QIIME, beinhalten die Zuweisung im eigenen Workflow im Zuge der Datenaufarbeitung [18, 44, 51]. Externe, spezifisch für diesen Schritt des Post-Sequencing Workflows, funktionierende Methoden sind etwa der RDP (Ribosomal Database Project) oder SINA (Silva Incremental Aligner) [18].

RDP basiert auf Ansatz eines einfachen Algorithmus, wobei die Übereinstimmung der Sequenzen geprüft wird [18, 52]. Zusätzlich zum Vergleichen und Zuordnen gibt es weitere Funktionen wie ein Überprüfen von Primern oder die Darstellung von Bäumen [53]. Bei dem Ansatz SINA wird ein Baum gebildet, der alle Sequenzen beinhaltet und als Referenz genutzt wird, um Sequenzen einzuteilen [18]. Dem Ansatz SINA liegt zum Vergleich die Gendatenbank SILVA zugrunde [54]. Wichtiger Faktor bei der Zuweisung der Taxonomie ist die Aktualität der verwendeten Datenbank. Viel genützte Datenbanken wie SILVA, GreenGenes und RDP werden ständig auf aktuellen Stand gebracht [18, 55].

4.3 Datensatz aufreinigen und filtern

Um zu Filtern, welche Sequenzen aus dem Datensatz echte biologische Informationen über die Probe geben, gibt es verschiedene Ansätze [18].

Der Algorithmus DADA2 (Divisive Amplicon Denoising Algorithm 2) gliedert Amplicons bezogen auf deren Häufigkeit und berechnet ein Fehlermodell

anhand von Cluster und verschiedenen Qualitätskriterien, um fehlerhafte Sequenzen zu korrigieren. DADA2 ist eine frei zugängliche Software, die keine Referenz benötigt und auf jeder Genregion angewendet werden kann [18, 37].

Der Ansatz CFF (Cluster-Free Filtering) läuft ähnlich ab wie der Algorithmus DADA2. Der Unterschied ist, dass fehlerhafte Sequenzen nicht korrigiert, sondern entfernt werden [18].

Ein weiterer Algorithmus, UNOISE, startet damit, OTUs zu entfernen, die selten auftreten (als Untergrenze oft eine OTU-Häufigkeit von 4 Zählungen) und erstellt folgend ein Fehlermodell. Der Algorithmus wird bei ganzen Datensätzen angewendet, nicht bei einzelnen Proben. Von UNOISE gibt es bereits die verbesserte Version UNOISE2. Damit wird die selbstständige Anpassung der Filterung ermöglicht. Die Funktion folgt dem gleichen Prinzip wie UNOISE. UNOISE2 und DADA2 besitzen ähnliche Genauigkeit in der Filterung des Datensatzes [18, 56]. Häufig werden die Algorithmen DADA2 und UNOISE kombiniert angewendet, da anhand ihrer unterschiedlichen Ansätze ein optimales Ergebnis der Filterung des Datensatzes erreicht werden kann [18].

Als rare OTUs werden OTUs definiert, die sich aufgrund von nur einer oder zwei Sequenzen bilden. Es ist möglich, dass aufgrund von PCR- oder Sequenzier-Fehler sich eine Sequenz deutlich vom Rest unterscheidet und somit eine OTU nur für diese entsteht. Nicht möglich ist, zwischen solchen rare OTUs, die entweder anhand von Fehlersequenzen gebildet werden oder solchen OTUs, die tatsächliche Sequenzen der Probe repräsentieren, zu unterscheiden. Die Entscheidung alle solche rare OTUs zu filtern, oder sie im Datensatz zu behalten hängt von dem Anwender/der Anwenderin ab. Großen Einfluss auf das Ergebnis haben rare OTUs, nutzt man statistische Ansätze zur Analyse der Datensätze [57, 58]. Unter Subsampling in der Datensatz Aufreinigung und Filterung versteht man OTUs die gebildet werden, sich jedoch untereinander kaum unterscheiden in Untergruppen zu teilen. Möglichkeit zu Subsampling ist das BAS (Balance-Aware Subsampling). Hier werden unterschiedliche Ergebnisse definiert, unter welchen das am besten geeignete herausgefiltert wird [59].

4.4 Statistische Analyse

Ausschlaggebend für die Aufarbeitung mittels statistischer Methoden ist, dass der Mensch Daten dargestellt über die Dreidimensionalität hinaus nicht verarbeiten kann. Die großen Daten an Proben und somit OTUs werden anhand statistischer Ansätze analysiert oder zusätzlich komprimiert. Varianzanalysen werden angewendet, um zu prüfen ob Proben, die bereits gruppiert sind, statistisch tatsächlich verschiedenen biologischen Gemeinschaften zugehören. Generell sind Varianzanalysen definierbar als Analysen von Daten und Strukturen durch statistische Ansätze. Zu den gebräuchlichsten Analysen zählen AMOVA (Analysis of Molecular Variance), HOMOVA (Homogeneity of Molecular Variance) und PERMANOVA (Permutational Analysis of Variance) [18].

AMOVA und HOMOVA basieren beide auf Algorithmen, die die Differenz von Gemeinschaften (Cluster) ermitteln. AMOVA vergleicht die Varianzen innerhalb solcher Gruppen, sowie zwischen den einzelnen Gruppen. HOMOVA berechnet die Abweichung innerhalb aller Gruppen und bestimmt somit den Grad der Vielfalt [60, 61]. Anhand PERMANOVA werden unterschiedliche Gruppen verglichen. Diese Methode ist die am Häufigsten genutzte und eignet sich idealerweise für kleine Probengrößen mit großer Vielfalt [62, 63].

Weitere statistische Methoden sind PCA (Principal Component Analysis), PCoA (Principal Coordinates Analysis) oder CA (Corresponding Analysis). Diese dienen als Ordnungsanalysen [18, 64]. PCA definiert einen Algorithmus der große Datensätze soweit komprimiert, dass die Vielfalt der Daten erhalten bleibt, die Menge und Dimensionalität jedoch reduziert wird [65]. Es handelt sich um eine der ältesten und am häufigsten genutzten Analysen [64]. Besser für Daten von Mikrobiomen geeignet ist die PCoA [18]. Diese Analyse ist eine adaptierte Methode der PCA. Unterschied zur PCA ist, dass die Organisation nicht nach bestimmter eigenen Proben-Matrix abläuft, sondern jede beliebige Matrix als Grundlage genutzt werden kann [64]. Nach Analyse durch PCA oder PCoA können die Proben grafisch dargestellt werden, um eine Visualisierung der Differenzen von Proben aufzuzeigen. Aus solchen Grafiken ist es zusätzlich leichter festzustellen, ob eine Proben-Gruppierung möglich ist [18, 65]. Ähnlich

zu diesen Ansätzen ist das Ziel der CA, die optimierte Korrespondenzanalyse. In ihren Methoden unterscheiden sich die Analysen jedoch [18, 64]. Bei der CA wird nach Beziehungen innerhalb von Spalten und Zeilen einer Proben-Matrix gesucht, die abschließend grafisch aufgezeigt werden sollen [64].

NMDS (Non-metric multidimensional Scaling) ist neben PCA, PCoA und CA eine ebenso oft angewendete Analysemethode. Mit NMDS werden anhand eines Algorithmus die Abstände innerhalb vorliegender Objekte berechnet. Das bedeutet, es wird der Grad ermittelt, inwieweit sich Gruppen unterscheiden oder ähnlich sind [64]. NMDS sorgt bei großen Datensätzen für bessere Übersicht, da diese Methode die Anzahl an Dimensionen einschränkt [18].

4.5 Alpha- und Beta-Diversität

Um zu evaluieren, ob biologische Vielfalt positiven Einfluss auf weitere Entwicklungen einer Gemeinschaft ausübt oder nicht, entwickelten Wissenschaftler in den letzten Jahrzehnten unterschiedliche Diversitätsindize, die Aussage über gegebene Frage geben sollen [66].

Definiert erstmals im Jahr 1960 bedeutet Alpha-Diversität die Vielfalt innerhalb einer Probe, eines Lebensraums oder generell innerhalb eines definierten biologischen Bereichs [67, 68]. Die einfachste Methode, diese Art zur Diversitätsbestimmung ist die unterschiedlichen OTUs einer Probensammlung zu zählen. Aufgrund der Unmöglichkeit, jede einzelne Taxonomie in einer Probe zu identifizieren, werden andere Methoden zur Bestimmung der Alpha-Diversität eingesetzt. Hierbei handelt es sich oft um statistische Ansätze. Werden OTUs in der Aufreinigung und Filterung des Datensatzes (Kapitel 4.3) entfernt, die nur selten auftreten und eine sehr kleine Gruppe repräsentieren, beeinflusst dies die Aussage der Alpha-Diversität [18, 68]. Neben der Alpha-Diversität wurde auch die Beta-Diversität im Jahr 1960 geprägt und definiert. Beta-Diversität zeigt den Unterschied der Vielfalt an Arten verschiedener Gemeinschaften auf [67, 68]. Die Beta-Diversität zeigt somit wie sich Proben voneinander unterscheiden bzw. ähnlich sind. Zur Messung dieser Maßzahl können unterschiedliche Ansätze angewendet werden [18].

Zwei der wichtigsten Diversitätsindize, um Artenvielfalt und deren Verteilung zu beschreiben, sind der Shannon- und Simpson-Index [68, 69]. Der Shannon-Index beschreibt wie vielfältig eine Gemeinschaft ist, der Simpson-Index wieviel einer bestimmten Art vorkommen [70, 71].

Weitere verwendete Methoden zur Analyse von bereits in OTUs geclusterte Sequenzen sind Metastats und LEfSe (Linear Discriminant Analysis Effect Size Method) [18]. Mit Metastats werden Metagenome durch Kombination von t-Tests und Fisher-Tests analysiert. Diese Verbindung führt dazu, dass geprüft wird wie und durch welche Merkmale sich Metagenome unterscheiden [72, 73]. Nutzt man den Algorithmus LEfSe, werden Merkmale von Cluster bestimmt, die für die Differenz dieser ausschlaggebend sind. Als solche Merkmale identifizierbar sind etwa Gene, Organismen oder Taxonomien. Zur Bestimmung werden statistische Standardtests gekoppelt mit zusätzlichen, bereits bekannten, biologischen Daten [72]. Als Core-Mikrobiom definiert ist eine bestimmte Gruppe bestehend aus Organismen, die sich in gleicher Gemeinschaft im selben Lebensraum befinden. Sie dient dazu, Lebensgemeinschaften darzustellen und Funktionen von grundlegenden Spezies zu ermitteln. Die Gliederung der Sequenzen in OTUs wird als Grundlage zur Definition verwendet. Ein Core-Mikrobiom lässt sich für unterschiedlichste Lebensgemeinschaften (Gewässer, Böden, Abwassersysteme) definieren [74].

Oftmals ist es sinnvoll verschiedene Ansätze zur Bestimmung der Diversitäten in Metagenom-Analysen zu kombinieren. Grund dazu ist, dass jeder Ansatz auf unterschiedlichen Faktoren basiert und somit verschiedene Charakteristiken einer Biozönose berücksichtigt. Werden jedoch Methoden verknüpft ergeben sich im Endeffekt genauere Gesamtbilder der zu untersuchenden Proben [18].

4.6 Darstellung der Ergebnisse

Um große komplexe Datensätze zu vereinfachen, werden sie oft in verschiedensten Grafiken in abgewandelter Form dargestellt. Abhängig vom Darstellungsformat beinhaltet dieses unterschiedlich viel Informationen über die Probe. Bei Grafiken kann mit unterschiedlichsten Merkmalen, wie Farbe, Punkte oder zusätzliche Achsen, Information markiert und hervorgehoben werden. Besonders wichtig bei der Darstellung der Ergebnisse mithilfe von Barcharts, Ordinationsplots oder auch phylogenetischen Bäumen, ist, dass keine falschen Kenntnisse aus den Darstellungsformaten herausgelesen werden können. Somit soll es für jeden Betrachter der Ergebnisse gleich interpretierbar sein [18].

Barcharts eignen sich gut, große Probenmengen darzustellen. Durch diese Art der bildlichen Darstellung lassen sich Informationen anhand von Balken wiedergeben. Für Barcharts gibt es unterschiedlichste Darstellungsmöglichkeiten. An die zu repräsentierenden Daten anpassbar sind etwa Balken, Achsen oder Balkenabstände [18, 75]. Weitere Form der Darstellung sind Streudiagramme oder Boxplots. Visualisiert man dieselben Daten in beiden Diagrammarten, erhält man eine unterschiedliche Informationsdichte. Beide Typen kombiniert ergeben ein Violinen-Diagramm, was zu optimaler Aussage und Interpretation der Daten führt, anstatt des Boxplots und Streudiagramms [18].

Die Darstellung der Ergebnisse mit phylogenetischen Bäumen wird häufig angewandt, um ökologische Muster in einer Grafik zu repräsentieren [69]. Weiters werden sie herangezogen, um Beziehungen zwischen Sequenzen oder Organismen aufzuzeigen. Allgemein lässt sich ein phylogenetischer Baum als das Bild über die Zusammenhänge von biologischen Gruppen beschreiben. Wendet man diese Darstellungsform speziell für bioinformatische Analysen an, lassen sich Beziehungen zwischen den definierten Taxonomien der untersuchten Proben aufzeigen [76]. Dargestellt sind phylogenetische Bäume mit sogenannten Knoten, die die spezifischen Einheiten repräsentieren und untereinander verbunden sind. Diese Verbindungen entsprechen Zweigen und ergeben somit das Bild eines Baumes [77].

In Abbildung 4 wird ein zufällig gewählter Datensatz in vier unterschiedlichen Darstellungsmöglichkeiten gezeigt. Es handelt sich um Zufallsproben (aus Quelle [18]) die ausschließlich dazu dienen, den Unterschied an Informationen zwischen verschiedenen Darstellungen aufzuzeigen. Bei den Daten handelt es sich um drei Normalverteilungen, die in deren Varianzen und Mittelwerten variieren. Diagramm a. stellt ein Streudiagramm mit seitlichen Histogrammen dar. In dieser Darstellung ist die Verteilung der Dichten erkenntlich. Im Diagramm b. werden jeder Verteilung verschieden farbliche, vordefinierte, Cluster zugrunde gelegt. Die Kreise umfassen 85 % der jeweiligen Daten der einzelnen Normalverteilungen. Diagramm c. unterteilt den Datensatz in

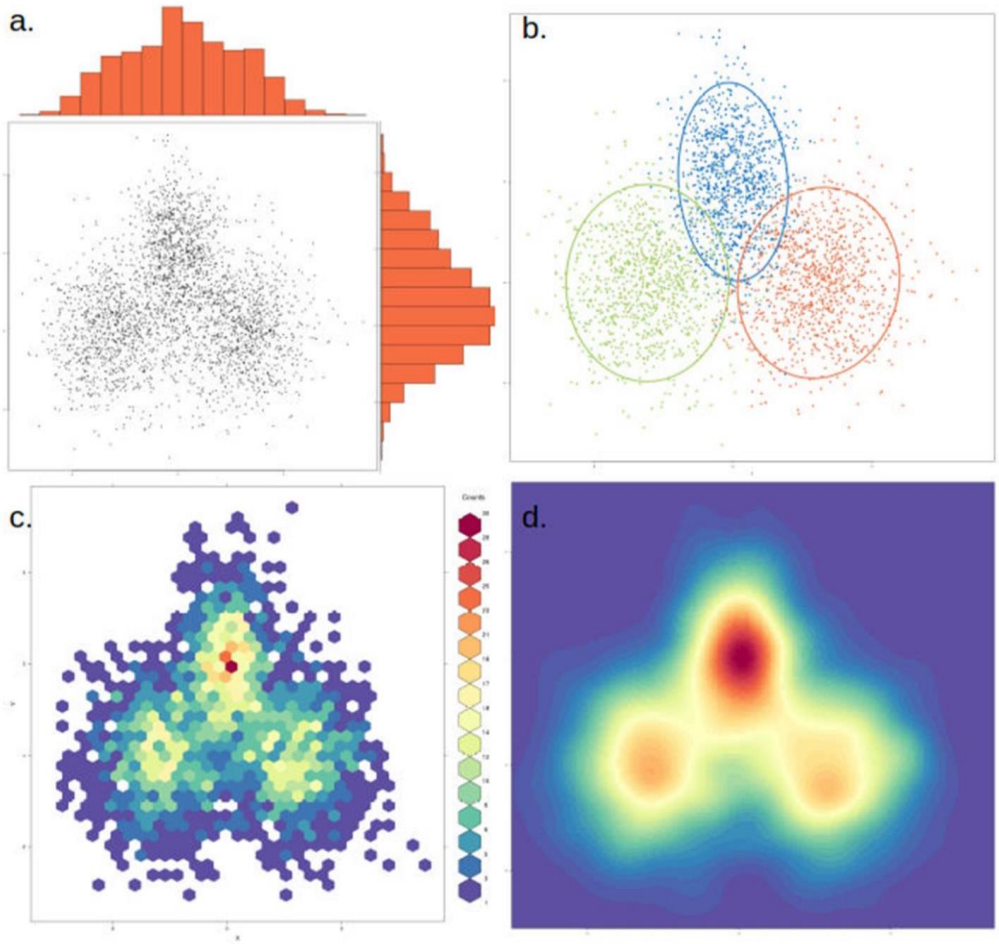

Abbildung 4: Darstellung eines beliebigen Datensatzes anhand vier unterschiedlicher Darstellungsmöglichkeiten. **a.**, Darstellung der Verteilung der Dichten in einem Streudiagramm mit Histogrammen. **b.**, Cluster entsprechen den bestimmten Verteilungen. 85 % jeder Verteilung liegen innerhalb des gekennzeichneten Kreises. **c.**, Hexagone repräsentieren den Datensatz. Dichten werden verschieden farblich definiert. **d.**, Darstellung **c** in angepasster (geglättet und interpoliert) Form [18].

Sechsecke (Hexagone) mit Erkennung der Dichte anhand verschiedener Farben. Zur Definition der Farbdichte liegt eine Legende vor. Im letzten Diagramm d. sind die Daten wie in c. dargestellt, jedoch in angepasster, interpolierter und geglätteter Form [18].

Zur grafischen Darstellung (Ordinationsplots, Barcharts, mehrdimensional und weitere Möglichkeiten) oder auch statistischen Analyse (Kapitel 4.4) wird häufig die frei zugängliche, Objekt-orientierte Programmiersprache R genutzt [78].

5 Anwendungsbeispiel

Das Anwendungsbeispiel basiert auf der Verarbeitung von Sequenzen aus 16S rRNA Illumina Amplicon paired-end Sequenzierung. Allgemein hängt der Ablauf der bioinformatischen Datenanalyse nicht von der Software ab. Es unterscheiden sich die Befehle der einzelnen Softwares, wie mothur oder QIIME, die genutzt werden, um vorliegende Datensätze nach Sequenzierung zu verarbeiten. Ein komprimierter Beispieldatensatz wurde verwendet, um den spezifischen Arbeitsablauf plus den verwendeten Befehlen, genutzten Funktionen, sowie Methoden der Software mothur zu verstehen [43, 44]. Folgende Schritte sind dazu gedacht, vorhandene Fehler aus dem Workflow Pre-Sequencing (Kapitel 3) und der Sequenzierungsmethode zu entfernen und die richtige Konstellation einer biologischen Gemeinschaft aufzuzeigen, die für weitere Analysen, grafisch oder statistisch, weiterverwendet werden können. Funktion, Ablauf und Arbeitsweise einzelner Schritte erfolgen nach dem MiSeq SOP (Standard Operating Procedure) der Software mothur [43].

Bei einer paired-end Sequenzierung wird von einem Fragment von beiden Enden (5‘-Ende und 3‘-Ende) sequenziert. Es liegen von jedem einzelnen Fragment der Probe zwei Sequenzen, abgelesen von unterschiedlichen Enden, vor. Es wird mit der Komprimierung und Korrektur des Datensatzes begonnen, sodass die zwei Sequenzen eines Fragments zu einer zusammengefasst werden.
Nutzt man speziell die Software mothur, konstruiert der Befehl „make.contigs(…)“ anhand der zwei Sequenzen eine Sequenz pro Fragment und speichert alle neuen, reduzierten Daten in einer neuen Datei [43].

In der Klammer nach dem Aufruf des Befehls (…) werden Parameter übergeben, die Aussage und Information über die Textdatei und des Computers geben, die von möglichen elektronischen Ressourcen des Anwenders/der Anwenderin abhängig sind. In allen folgenden aufgezählten Befehlen, spezifisch für die Software mothur, werden diese Klammern (…) ebenso dargestellt. Während des Workflows wird oft ein Befehl ausgeführt, der dazu dient, Informationen zu den aktuell vorliegenden Sequenzen in Tabellenformat aufzulisten und diese in neuen Dateien zu speichern. Dies dient als aktuelle

Zusammenfassung, die für die weitere Datenaufbereitung verwendet werden kann.
In mothur zeigt dies der Befehl „summary.seqs(…)“ und liefert Informationen zur Verteilung der Fragmente anhand deren Länge, die Gesamtanzahl an vorliegenden Fragmenten, sowie die (Gesamt-)Anzahl an Polymere und Ambigs [43].

Um sicher zu sein, dass Sequenzen bestimmte Eigenschaften erfüllen, werden anhand des Anwenders/der Anwenderin bestimmte Parameter definiert, wie die maximale Länge oder maximale Anzahl an Ambigs, von Sequenzen. Alle Sequenzen, die etwa die angegebene Länge überschreiten, werden aus dem Datensatz entfernt.
Verwendet man die Software mothur übernimmt „Screen.seqs(…)“ diese Filterung. Der Anwender/Die Anwenderin übergibt die bestimmten Parameter mit Aufruf dieser Funktion [43].

In einem Datensatz liegen viele verschiedene Sequenzen vor, jedoch gibt es von den Sequenzen selbst eine große Anzahl an Kopien. Um unnötig lange Rechenzeiten und Speicherplatz am Computer zu vermeiden, werden alle Sequenzen auf eine einzeln vorliegende Kopie jeder Sequenz im Datensatz reduziert.
Bei mothur erreicht man eine solche Verkleinerung der Daten mithilfe „unique.seqs(…)“. Sind zwei Sequenzen ident, werden sie zusammengeführt [43].

Um einen Überblick über die vorhandenen Sequenzen zu bekommen wird eine Tabelle erstellt, die die Namen und Gruppen der Sequenzen sortiert. „Count.seqs(…)“ generiert bei der Software mothur eine solche Tabelle. In den Zeilen stehen die Namen und in den Spalten die Gruppen der Sequenzen. Im späteren Ablauf der Analyse durch mothur nutzt man diese erstellte Tabelle, indem die Häufigkeit der vorkommenden Sequenz jeder Gruppe zugeordnet wird [43].

Verwendet man mothur, so wird nach obigem Schritten meist wieder der aktuelle Stand mit „summary.seqs(…)“ aufgelistet und in neuen Files gespeichert.

Nächster Schritt ist, die vorliegenden Sequenzen an die 16S rRNA anzugleichen. Bis jetzt startet jede Sequenz bei Basennummer 1. Das Angleichen an die 16S rRNA bedeutet, dass die einzelnen Sequenzen mit den komplementären Abschnitten auf der 16S rRNA gegenübergestellt werden. Findet sich die bestimmte Sequenz in einer bestimmten Region, übernimmt sie die Nummerierung der Position der Vergleichssequenz.
Bei mothur erfolgt dieser Schritt mithilfe von „align.seqs(…)“. Wichtig ist, dass mit Aufruf des Befehls die zu verwendende Referenzdatenbank mit den Vergleichsequenzen der 16S rRNA übergeben wird, damit das Programm weiß, mit welcher Datenbank verglichen werden soll. Nach diesem Schritt wird in mothur ebenfalls die Zusammenfassung und übersichtliche Darstellung mit „summary.seqs(…)“ durchgeführt [43].

Nach richtiger Definition der Start- und Stopppositionen, werden Sequenzen, die über die Regionen hängen gekürzt und an die Abschnitte der V-Regionen angepasst.
Erfolgt die Analyse mittels mothur, wird „screen.seqs(…)“ aufgerufen. Übergabeparameter sind die zuvor ermittelten Start- und Stopppositionen, sowie eine eigens definierte maximale Anzahl an Homopolymeren. „Summary.seqs(…)“ dient folglich wieder als Übersicht [43].

Aus dem Datenbankvergleich entstandene Sequenzen können nach Zuweisung der Tabellen nur Lückenfüllzeichen, wie Punkte oder Bindestriche (z.B. „.“ oder „-“) enthalten. Mithilfe eines Filterungsschrittes werden alle solche Füllzeichen entfernt, ohne Informationen über den Datensatz zu verlieren. Dieser Filterungsschritt läuft bei der Beispielsoftware mothur mit dem Befehl „filter.seqs(…)“ ab. Als Parameter im Befehl können spezifische, zu entfernende Zeichen durch den Anwender/die Anwenderin definiert werden [43].

Durch die Löschung von Lückenfüllzeichen ist es möglich, dass wieder Sequenzen im Datensatz vorliegen, die ident sind. Somit wird folgend erneut

der Schritt durchgeführt, der jede Sequenz auf eine vorliegende Kopie reduziert. Es handelt sich bei mothur wieder um den Befehl „unique.seqs(…)“ [43].

Die bis jetzt aufbereiteten und komprimierten Daten werden einer ersten Vorgruppierung unterzogen. Unterscheiden sich Sequenzen innerhalb einer bestimmten Sequenzlänge (meist 100 bp) um eine maximal definierte Anzahl an bp und sind somit fast ident, werden sie in demselben Cluster gruppiert. Mit Aufruf der Methode „pre.cluster(…)“ verwendet die Software mothur einen Algorithmus [79], der die Sequenzen anhand deren Häufigkeit sortiert. Kozich et. al. empfehlen pro 100 bp Sequenz einen maximalen Unterschied von einem bp, um demselben Cluster zugeordnet zu werden. Diese erlaubte Differenz wird durch den Anwender/die Anwenderin als Parameter festgelegt [43].

Folgender Schritt zählt zu den Filterschritten. Es werden alle chimären Sequenzen bestimmt. Einerseits ist es möglich, diese zu definieren und sofort zu entfernen. Andererseits können alle chimären Sequenzen ermittelt, in einer Datei gespeichert und im nächsten Schritt („remove.seqs(…)“ in mothur) entfernt werden.
Es gibt zwei Möglichkeiten an Algorithmen, Chimäre mit der Software mothur zu identifizieren: „chimera.uchime(…)“ und „chimera.vsearch(…)“ [43]. Beide Methoden werden unter OTU clustering und Zuweisung der Taxonomie (Kapitel 4.2) näher beschrieben.

Werden die Chimären zuvor nur bestimmt, ist es nötig diese im Folgeschritt zu entfernen.
„Remove.seqs(…)“ löscht aus allen Sequenzen, die in einer Datei vorliegen und als Parameter dienen, die zuvor bestimmten Chimären. Die Chimäre werden ebenfalls dem Befehl als Parameter in Form ihres Dateiformates übergeben. Nach diesem Schritt nutzt mothur oftmals „summary.seqs(…)“ um den aktuellen Überblick über die wichtigsten Informationen des Sequenzdatensatzes darzustellen und erneut zu speichern [43].

Nach Entfernung der Chimären werden die Sequenzen anhand einer Vergleichsdatenbank ihrer Taxonomie zugeordnet. Zu beachten ist, dass die Zuweisung für viele Gruppen durchgeführt wird, wie Bakterien, Archaea oder

Eukaryoten.
Nutzt man mothur, erfolgt die Zuordnung der Taxonomie mit der Methode „classify.seqs(…)“. Die festzulegenden Parameter sind die gewünschte Vergleichsdatenbank, sowie eine Grenze, bis zu welchem Prozentsatz an Übereinstimmung (häufig bei 80 %) eine nicht zu klassifizierende Sequenz vorliegt. Die bestimmten Taxonomien speichert das Programm in einer Excel-Datei [43].

Da aufgrund der Zuweisung die Taxonomien nicht nur von Bakterien, sondern auch von Archaea oder Eukaryoten erfasst werden, muss man die ungewünschten Gruppen definieren und gegebenfalls herausfiltern. Aus einer Mischung von Chloroplasten, Archaea, Eukaryoten, Mitochondrien, Bakterien, sowie nicht zugeordnete Sequenzen („unknown“) werden mit „remove.lineage(…)“ bei mothur die Daten auf die gewünschte, zu analysierende, Domäne reduziert [43].

Neben der Zusammenfassung über die aktuellen Daten in einer Tabelle, bei mothur „summary.seqs(…)“, kann der gefilterte Datensatz ebenso in anderen Dateiformaten gespeichert werden. „Summary.tax(…)“ erstellt eine Excel-Datei, die alle zusammengefassten Taxonomien der gewünschte Domäne auflistet [43].

Abhängig von dem Anwender/von der Anwenderin wird neben der eigenen Probe eine zusätzliche Kontrollprobe parallel sequenziert und analysiert. Die taxonomische Zusammensetzung dieser Kontrollprobe ist im Vorhinein bekannt und macht es möglich, die Qualität der Sequenzierung und Analyse zu bestimmen. Empfehlenswert ist, nicht bei jeder Analyse eine Kontrollprobe mitlaufen zu lassen, da dies viel Zeit und Speicherplatz in Anspruch nimmt. Kozich et. al. lassen alle 95 Sequenziervorgänge plus folgender bioinformatischer Analyse eine Kontrollprobe mitlaufen. Wird nun eine Überprüfung durchgeführt, muss der Datensatz dieser Kontrolle entfernt werden. Bei mothur löscht der Befehl „remove.groups(…)“ die Kontrollsequenzen [43].

Da die Sequenzen bereits gefiltert und vorgruppiert sind, findet im Anschluss die Hauptauftrennung der Sequenzen in OTUs anhand deren Ähnlichkeiten statt.
Bei der Beispielsoftware mothur trennt der Befehl „cluster.split(…)“ die Sequenzen nach bestimmten Prozentsatz (übergebener Parameter, meist 97 %) an Ähnlichkeit. Mit „make.shared(…)“ lässt sich darstellen, wie viele Sequenzen einer OTU zugeordnet werden. Folgt darauf der Befehl „classify.otu(…)“ im Programm mothur, wird jeder OTU die Taxonomie zugeordnet [43].

Nach Ablauf all dieser Filter-, Gruppierungs- und Zuweisungsschritte können die Daten, unabhängig von der genutzten Software, weiterverwendet werden, um die biologische Gemeinschaft graphisch oder statistisch detaillierter zu analysieren. Möglichkeiten an statistischen Analysen und Darstellungen der Ergebnisse finden sich in den jeweiligen Kapiteln – statistische Analysen (Kapitel 4.4), Darstellung der Ergebnisse (Kapitel 4.6).

6 Zusammenfassung und Diskussion

In vielen wissenschaftlichen Artikeln werden grundsätzliche Workflows zur bioinformatischen Datenanalyse beschrieben. Auch diese Arbeit stellt einen solchen Ablauf dar – bezogen auf Sequenzierungs-Methoden auf Basis der 16S rRNA Illumina Amplicon Sequenzierung, sowie nachfolgender bioinformatischer Analyse der Datensätze.

6.1 Sequencing-Methoden

Sequencing-Methoden lassen sich in drei Generationen einteilen. Zur ersten Generation zählen klassische Methoden, wie die Kettenabbruchmethode nach Sanger, oder die chemische Spaltungs-Methode nach Maxam und Gilbert. Beide Methoden stellen die ersten Sequenzierungsmöglichkeiten dar. Viele neuartigere Methoden basieren auf der Sanger Sequenzierung. Moderne Methoden, die NGS-Methoden, sind zum Beispiel die Pyrosequenzierung, IonTorrent und Illumina Sequenzierung. Bei der Pyrosequenzierung und IonTorrent erfolgt die Amplifikation der template DNA anhand von emPCR. Betrachtet man im Gegensatz dazu die Illumina Sequenzierung, erfolgt die Erstellung der template Moleküle durch Brücken-Amplifizierung. Aktuellste Methoden nennt man Methoden dritter Generation. Beispiel hierzu ist die Nanopore Sequenzierung, bei welcher die zu sequenzierenden DNA Stränge durch eine Nanopore bewegt werden. Die ständige Verbesserung der Technologien führt dazu, dass Sequenzierungen weniger zeitintensiv und kostengünstiger werden.

6.2 Workflow Pre-Sequencing

Der Workflow Pre-Sequencing wird in dieser Arbeit in fünf Teilschritte gegliedert: die Probensammlung und -lagerung, die DNA-Extraktion, die Agarose Gelelektrophorese, die DNA-Quantifizierung und Qualitätsprüfung mittels NanoDrop® oder Quantus™ und in die 16S rRNA target Region und Wahl der Primer. Die Probensammlung und -lagerung hängt von der Art und der Herkunft der zu analysierenden Probe ab. Für jede Art gibt es Methoden zur Probennahme. Empfohlene Lagerung der Proben bis zur DNA-Extraktion erfolgt

bei -80 °C. Eine wichtige Eigenschaft von Proben ist die Repräsentativität und um aussagekräftige sowie statistisch auswertbare Ergebnisse zu erreichen sind mehrere Replikate nötig. Die wichtigsten Methoden zur DNA-Extraktion sind die mechanische bzw. chemisch-enzymatische Lyse oder die Phenol-Chloroform Extraktion. Ziel dieses Schrittes ist, maximale Ausbeute zu erreichen, um die biologische Gemeinschaft bestmöglich zu repräsentieren. Anhand der Agarose Gelelektrophorese wird der Erfolg der Extraktion kontrolliert, sowie die Fragmentlängen bestimmt. Um einen optimalen Sequenzierungsablauf zu garantieren wird die Qualität und Quantität der DNA vorher bestimmt. Dies erfolgt anhand von Fluorometrie und Spektrophotometrie. Verwendete Geräte sind etwa der NanoDrop® der Firma Thermo Fisher Scientific und der Quantus™ vom Unternehmen Promega. Der vor der Sequenzierung abschließende Schritt ist die Amplifikation der target Regionen. Abhängig vom Organismus werden verschiedene Regionen der Sequenz amplifiziert. Um eine erfolgreiche Amplifizierung zu ermöglichen ist die Auswahl der genutzten Primer ausschlaggebend. Verschiedene Programme, wie PrimerProspector oder DegePrime, unterstützen das Finden optimaler Primer. Der Workflow Pre-Sequencing stellt eine wichtige Grundlage für die Sequenzierung dar. Werden die Abläufe korrekt durchgeführt, können viele Fehler vermieden werden, die in der Sequenzierung und im Endergebnis großen Einfluss hätten.

6.3 Workflow Post-Sequencing

Der Workflow Post-Sequenzierung teilt sich in sechs Schritte: das Quality Screening, das OTU clustering und Zuweisung der Taxonomie, die Datensatz Aufreinigung und Filterung, die statistische Analyse, die Alpha- und Beta-Diversität und die Darstellung der Ergebnisse. Im Quality Screening werden Fehler der Sequenzierung und PCR gesucht und definiert. Diese Fehler werden entweder behoben oder die Sequenzen ganz gelöscht. Häufige Fehler sind Chimäre, Homopolymere und Ambigs. Chimäre werden durch Vergleiche mit Datenbanken und Programmen wie UCHIME oder VSEARCH bestimmt und gefiltert. Software wie mothur oder QIIME nutzen bestimmte Methoden und Befehle in ihren Programmen, um Homopolymere oder Ambigs zu definieren und zu löschen. Um vorgefilterte Sequenzen zu gruppieren werden sie in OTUs

zusammengefasst. Nach dem OTU clustering erfolgt die Zuweisung der Taxonomie. Es gibt unterschiedliche Ansätze und Datenbanken, die als Referenz verwendet werden können, um ähnliche Sequenzen bestimmten Gruppen zuzuordnen. Mithilfe von Algorithmen und Methoden wie DADA2, CFF oder UNOISE können die Datensätze weiter aufgereinigt und gefiltert werden. Eine weitere Komprimierung der Daten führt zu schnellerer Laufzeit der Programme, bessere Übersicht über den Datensatz und weniger benötigten Speicher am Computer. Statistische Analysen der bis hier aufgereinigten und sortierten Sequenzen verbessern die Möglichkeiten der Darstellungen und Interpretation der Daten. Die gebräuchlichsten statistischen Ansätze sind AMOVA, HOMOVA und PERMANOVA. Die Vielfalt der Probe kann anhand verschiedener Diversiätsindizes bestimmt werden. Die wichtigsten Indizes sind der Shannon- und Simpson-Index, weitere Methoden sind LEfSe und die Definition eines Core-Mikrobioms. Zuletzt nutzt man diverse Darstellungsmöglichkeiten, um die Ergebnisse einer bioinformatischen Analyse kompakt aufzuzeigen. Arten der Darstellung sind Barcharts, phylogenetische Bäume, Boxplots oder Streudiagramme.

6.4 Anwendungsbeispiel

Das Anwendungsbeispiel basiert auf der bioinformatischen Software mothur. Mithilfe dieses Beispiels soll der Ablauf einer Analyse von biologischen Gemeinschaften nach der Sequenzierung besser verstanden werden. Grundsätzlich laufen alle Softwares nach dem gleichen Prinzip ab, um Daten nach der Sequenzierung aufzubereiten und auszuwerten, bis hin zur statistischen Analyse und grafischen Darstellung. Allgemein ist es schwierig einen generell gültigen Workflow für bioinformatische Datenanalysen zu definieren.

7 Ausblick

In dieser Arbeit wird der Ablauf einer bioinformatischen Datenanalyse, sowie vorangegangener Sequencing-Methode in grundlegender Form dargestellt. Fakt ist, dass sich anhand der stetigen Entwicklung neuer und fortschrittlicherer Technologien – sowohl in den Sequencing-Methoden als auch in der Datenanalyse – der optimale Workflow einer Analyse biologischer Gemeinschaften im stetigen Wandel befindet. Einige der in den letzten Jahrzehnten sich bewährten Werkzeuge, Softwares und Programme werden in die Arbeit eingebunden, sollen jedoch die Auswahl an den zu nutzenden Tools nicht nur auf diese beschränken. Wichtig ist, dass bei umfassenderen Datenanalysen die Arbeitsabläufe stets an die gegebenen Forschungsfragen anpasst werden. Von der gewählten Sequencing-Methode, bis hin zur statistischen Analyse und grafischen Darstellung der Ergebnisse, jeder einzelne Schritt des Workflows hängt vom aktuellen Projekt ab und soll anhand diesem abgestimmt und idealisiert werden.

Literaturverzeichnis

[1] M.-T. Hütt, M. Dehnert, *Methoden der Bioinformatik*, Springer Berlin Heidelberg, Berlin, Heidelberg **2016**.

[2] R. Renneberg, D. Süßbier, V. Berkling, V. Loroch, *Biotechnologie für Einsteiger*, 5th ed., Springer Spektrum, Berlin **2018**.

[3] R. D. Schmid, *Taschenatlas der Biotechnologie und Gentechnik*, 3rd ed., Wiley-VCH, s.l. **2016**.

[4] J. Pollock, L. Glendinning, T. Wisedchanwet, M. Watson, *Applied and environmental microbiology* **2018**, *84 (7)*, 1.

[5] J. M. Heather, B. Chain, *Genomics* **2015**, *107 (1)*, 1.

[6] N. A. Campbell, J. B. Reece, L. A. Urry, *Biologie*, 10th ed., Pearson Deutschland GmbH, Hallbergmoos **2016**.

[7] H. P. J. Buermans, J. T. den Dunnen, *Biochimica et biophysica acta* **2014**, *1842 (10)*, 1932.

[8] J. Besser et al., *Clinical microbiology and infection the official publication of the European Society of Clinical Microbiology and Infectious Diseases* **2018**, *24 (4)*, 335.

[9] A. M. Maxam, W. Gilbert, *Biochemistry* **1976**, 560.

[10] T. Rajesh, M. Jaya, in *Current Developments in Biotechnology and Bioengineering*, Elsevier **2017**.

[11] J. Myers, J. Rothberg, *Journal of biomolecular techniques* **2011**, 41.

[12] M. Margulies et al., *Nature* **2005**, *437 (7057)*, 376.

[13] S. J. Salipante et al., *Applied and environmental microbiology* **2014**, *80 (24)*, 7583.

[14] S. J. Salipante et al., *PloS one* **2013**, *8 (5)*, e65226.

[15] S. Sunagawa et al., *Nature methods* **2013**, *10 (12)*, 1196.

[16] D. Stein, *Biophysical Journal* **2015**, *109 (10)*, 2001.

[17] Y. Feng et al., *Genomics, proteomics & bioinformatics* **2015**, *13 (1)*, 4.

[18] L. W. Hugerth, A. F. Andersson, *Frontiers in microbiology* **2017**, *8*, 1.

[19] S. Linnarsson, *Experimental cell research* **2010**, *316 (8)*, 1339.

[20] G. Certini, C. D. Campbell, A. C. Edwards, *Soil Biology and Biochemistry* **2004**, *36 (7)*, 1119.

[21] F. Fouhy et al., *PloS one* **2015**, *10 (3)*, e0119355.

[22] J. M. Choo, L. E. X. Leong, G. B. Rogers, *Scientific reports* **2015**, *5*, 16350.

[23] P. Maksimov et al., *Veterinary parasitology* **2017**, *237*, 83.

[24] Macherey-Nagel, *Genomic DNA from soil: User manual* **2019**.

[25] S. Götze, R. Saborowski, *Analytical biochemistry* **2011**, *413 (2)*, 203.

[26] J. Carvalho et al., *Microchemical Journal* **2018**, *138*, 424.

[27] Promega Corporation, *Quantus™ Fluorometer Operating Manual: Instructions for Use of Product* **2018**.

[28] D. C. Harris, G. Werner, T. Werner, *Lehrbuch der Quantitativen Analyse*, 8th ed., Springer Spektrum, Berlin **2014**.

[29] M. H. Gey, *Instrumentelle Analytik und Bioanalytik*, Springer Berlin Heidelberg, Berlin, Heidelberg **2015**.

[30] S. Chakravorty et al., *Journal of microbiological methods* **2007**, *69 (2)*, 330.

[31] N. Chaudhary et al., *PloS one* **2015**, *10 (2)*, e0116106.

[32] F. González-Candelas, F. X. López-Labrador, in *Brenner's Encyclopedia of Genetics*, Elsevier **2013**.

[33] M. Martinez-Porchas, E. Villalpando-Canchola, L. E. Ortiz Suarez, F. Vargas-Albores, *PeerJ* **2017**, *5*, 1-20.

[34] N.-P. Nguyen, T. Warnow, M. Pop, B. White, *NPJ biofilms and microbiomes* **2016**, *2*, 16004.

[35] W. Walters et al., *mSystems* **2015** *(1)*, 1.

[36] C. L. Schoch et al., *Proceedings of the National Academy of Sciences of the United States of America* **2012**, *109 (16)*, 6241.

[37] B. J. Callahan et al., *Nature methods* **2016**, *13 (7)*, 581.

[38] W. A. Walters et al., *Bioinformatics (Oxford, England)* **2011**, *27 (8)*, 1159.

[39] L. W. Hugerth et al., *Applied and environmental microbiology* **2014**, *80 (16)*, 5116.

[40] E. Marinier, D. G. Brown, B. J. McConkey, *BMC Bioinformatics* **2015**, *16*, 10.

[41] R. C. Edgar et al., *Bioinformatics (Oxford, England)* **2011**, *27 (16)*, 2194.

[42] T. Rognes et al., *PeerJ* **2016**, *4*, 1-22.

[43] J. J. Kozich et al., *Applied and environmental microbiology* **2013**, *79 (17)*, 5112.

[44] P. D. Schloss et al., *Applied and environmental microbiology* **2009**, *75 (23)*, 7537.

[45] A. López-García et al., *Frontiers in microbiology* **2018**, *9*, 3010.

[46] G. Ivády et al., *BMC genomics* **2018**, *19 (1)*, 158.

[47] S. Shin, J. Park, *Nucleic acids research* **2014**, *42 (7)*, 1-11.

[48] B. D. Lindahl et al., *The New phytologist* **2013**, *199 (1)*, 288.

[49] J. R. Rideout et al., *PeerJ* **2014**, *2*, 1-25.

[50] S. L. Westcott, P. D. Schloss, *PeerJ* **2015**, *3*, 1-23.

[51] J. G. Caporaso et al., *Nature methods* **2010**, *7 (5)*, 335.

[52] Q. Wang, G. M. Garrity, J. M. Tiedje, J. R. Cole, *Applied and environmental microbiology* **2007**, *73 (16)*, 5261.

[53] J. R. Cole et al., *Nucleic acids research* **2014**, *42 (Database issue)*, 633-642.

[54] E. Pruesse, J. Peplies, F. O. Glöckner, *Bioinformatics (Oxford, England)* **2012**, *28 (14)*, 1823.

[55] T. Z. DeSantis et al., *Applied and environmental microbiology* **2006**, *72 (7)*, 5069.

[56] R. C. Edgar, *UNOISE2: improved error-correction for Illumina 16S and ITS amplicon sequencing* **2016**.

[57] N. A. Bokulich et al., *Nature methods* **2013**, *10 (1)*, 57.

[58] V. Kunin, A. Engelbrektson, H. Ochman, P. Hugenholtz, *Environmental microbiology* **2010**, *12 (1)*, 118.

[59] R. Wald, T. M. Khoshgoftaar, A. Fazelpur, *The Use of Balance-Aware Subsampling for Bioinformatics Datasets: 14 - 16 Aug. 2013, San Francisco, California, USA ; [including workshops*, IEEE, Piscataway, NJ **2013**.

[60] P. D. Schloss, *The ISME journal* **2008**, *2 (3)*, 265.

[61] L. Excoffier, P. E. Smouse, J. M. Quattro, *Genetics* **1992**, *131 (2)*, 479.

[62] Z.-Z. Tang, G. Chen, A. V. Alekseyenko, *Bioinformatics (Oxford, England)* **2016**, *32 (17)*, 2618.

[63] B. J. Kelly et al., *Bioinformatics (Oxford, England)* **2015**, *31 (15)*, 2461.

[64] O. Paliy, V. Shankar, *Molecular ecology* **2016**, *25 (5)*, 1032.

[65] M. Ringnér, *Nature Biotechnology* **2008**, 303.

[66] D. Davydov, S. Weber, *Economics Letters* **2016**, *147*, 121.

[67] R. H. Whittaker, *Ecological Monographs* **1960**, *30 (3)*, 279.

[68] C. O. McCoy, F. A. Matsen, *PeerJ* **2013**, *1*, 1-17.

[69] M. W. Cadotte et al., *Ecology letters* **2010**, *13 (1)*, 96.

[70] H. Nagendra, *Applied Geography* **2002**, 175.

[71] S. Pavoine, C. Ricotta, *Ecological Indicators* **2019**, *101*, 552.

[72] N. Segata et al., *Genome biology* **2011**, 1.

[73] J. R. White, N. Nagarajan, M. Pop, *PLoS computational biology* **2009**, *5 (4)*, 1-11.

[74] A. Shade, J. Handelsman, *Environmental microbiology* **2012**, *14 (1)*, 4.

[75] S. Elzer, S. Carberry, I. Zukerman, *Artificial Intelligence* **2011**, *175 (2)*, 526.

[76] G. Weyenberg, R. Yoshida, in *Encyclopedia of Evolutionary Biology*, Elsevier **2016**.

[77] R. J. Edwards, in *Encyclopedia of Bioinformatics and Computational Biology*, Elsevier **2019**.

[78] M. Milano, in *Encyclopedia of Bioinformatics and Computational Biology*, Elsevier **2019**.

[79] S. M. Huse, D. M. Welch, H. G. Morrison, M. L. Sogin, *Environmental microbiology* **2010**, *12 (7)*, 1889.

Abbildungsverzeichnis

Abbildung 1: Ablauf der Kettenabbruchmethode. 3
Abbildung 2: Erstellung der template Moleküle bei Illumina Sequenzierung. 7
Abbildung 3: Aufbau der Apparatur einer Gelelektrophorese. 13
Abbildung 4: Darstellung eines beliebigen Datensatzes. 25

Abkürzungsverzeichnis

A	Adenin
Ambigs	ambiguous bases
AMOVA	Analysis of Molecular Variance
BAS	Balance-Aware Subsampling
bp	Basenpaar/e
C	Cytosin
CA	Corresponding Analysis
CFF	Cluster-Free Filtering
DADA2	Divisive Amplicon Denoising Algorithm 2
ddNTP	Didesoxyribonukleosid-Triphosphate
dsDNA	doppelsträngige Desoxyribonukleinsäure
DNA	Desoxyribonukleinsäure
dNTP	Desoxyribonukleosid-Triphosphate
emPCR	Emulsions Polymerase Kettenreaktion
G	Guanin

HOMOVA	Homogeneity of Molecular Variance
H^+	positiv geladenes Wasserstoffion
ITS	Internal Transcribed Spacer
LEfSe	Linear Discriminant Analysis Effected Size Method
NGS	Next Generation Sequencing
NMDS	Non-metric multidimensional Scaling
OTU	Operational Taxonomic Unit
PCA	Principal Component Analysis
PCoA	Principal Coordinates Analysis
PCR	Polymerase Kettenreaktion
PERMANOVA	Permutational Analysis of Variance
RDP	Ribosomal Database Project
rRNA	ribosomale Ribonukleinsäure
SINA	Silva Incremental Aligner
SOP	Standard Operating Procedure
ssDNA	einzelsträngige Desoxyribonukleinsäure
T	Thymin